Huge PRD — AI 모의면접 채용 플랫폼 v1.3

> **Huge** · AI가 함께하는 더 나은 채용의 시작 — Good People, Great Teams 제작 · **AIIT** (AI Interview Training)
>
> 근거 문서: AI채용플랫폼_기술아키텍처_v0.7, AI채용 플랫폼 Mermaid v0.4, AI채용플랫폼_코딩테스트_v0.6, PRD v1.2, **TRD v1.0 작성 중 의사결정(2026-10-26)** v1.3은 TRD v1.0 작성 과정에서 확인된 문서 간 모순과 공백에 대한 결정을 반영한다. 기술 세부는 `AI채용플랫폼_TRD_v1.0/TRD_AI채용플랫폼_v1.0.md`를 따른다.

v1.2 → v1.3 변경 요약

1. **진행 순서 고정**: "면접 → 코딩테스트" 순서를 고정한다. 공고별 순서 변경 기능은 제공하지 않는다(화면정의서에 순서 변경 UI·역순 흐름이 없어 고정으로 통일). (5.1, 6.4)
2. **AI 처리 전부 온프레미스**: 코딩테스트 LLM뿐 아니라 면접 질문 생성·꼬리질문·평가·공고 자동 생성 LLM과 STT/TTS까지 모두 자체 호스팅으로 운영한다. 외부 AI API는 쓰지 않는다. (6.4, 7.1, 7.5, 9장)
3. **면접 동시 응시 상한**: GPU 한 대로 모든 AI 처리를 하므로 동시에 진행되는 면접 수에 상한을 둔다. 상한을 넘으면 "이미 많은 면접자들이 면접 중입니다. 추후 다시 요청해주세요."를 안내한다. 예상 대기 시간은 서버에서 계산해 두되 화면 표시는 후속 버전으로 미룬다. (6.3)
4. **화면 이탈 강제 종료 처리**: 새 상태 `TERMINATED`로 기록하고, 그때까지 답한 문항만 평가한다. **답하지 않은 기본 문항은 0점**으로 총점에 넣는다. (6.3, 6.5)
5. **코딩테스트 공개 범위 재정의**: "정상/비정상 작동만 공개"를 두 단계로 나눈다. **응시 중 중간 체크(실행)**에서는 실행 오류 여부(정상 작동/비정상 작동)를, **제출 후 최종 체크**에서는 정답 일치 여부("테스트 정답을 맞히셨습니다" / "맞히지 못했습니다")를 공개한다. 세부 점수·근거는 계속 관리자 전용이다. (6.4, 6.5, 7.2, 7.4)
6. **평가 완료 사이트 내 알림**: 평가가 끝나면 메일이 아니라 **사이트 내 알림(상단 알림 아이콘)**으로 알린다. 평가 처리 시간도 단축한다(면접 진행 중 답변별 선평가). (6.5, 6.7, 7.1)
7. **공고 자동 생성 차별 표현 주의 표시**: AI 초안 미리보기에서 차별 소지가 있는 표현에 밑줄과 경고를 표시한다. 게시를 차단하지는 않는다. (10장)
8. **브랜드 자산 정비**: 로고·마스코트·파비콘 웹용 자산을 `brand/` 폴더에 만들고, 마스코트 일러스트를 대기·완료·빈 화면에 사용한다. (화면정의서 v1.3)
9. **면접 문항 단위 확정**: 문항 수는 **기본 10문항 기준**으로 센다. 꼬리질문은 별도 문항으로 세지 않고 꼬리질문을 만든 기본 문항에 포함한다(면접 전체 최대 4개). 진행 표시는 "3 / 10", 강제 종료 안내는 "10문항 중 N문항"으로 표시한다. (6.3, 6.5)

---

1. 제품 개요

Huge는 AI 기반 모의면접·채용 플랫폼이다. 지원자가 공개 채용공고를 탐색하고 지원서를 제출하면, AI가 음성 기반 모의면접(질문 제시 → 답변 → 꼬리질문)을 진행하고, 이어서 직무별 코딩테스트(관리자가 공고별로 체크박스로 선택 적용)를 진행한 뒤 자동으로 평가 리포트를 생성한다. **면접 평가 결과(점수/피드백)는 지원자에게 공개되며, 코딩테스트는 응시 중 실행 오류 여부와 제출 후 정답 일치 여부만 공개되고 세부 평가는 채용담당자만 열람한다.** 모든 AI 처리는 사내(온프레미스)에서 이뤄진다. 기업 관리자는 AI 평가를 참고해 최종 채용 여부를 사람이 직접 결정한다.

2. 개발 목적

- 반복적인 1차 면접/서류 스크리닝에 드는 채용 담당자의 시간 부담을 줄인다.
- 고정된 루브릭과 가중치로 평가해 면접관·심사자 간 평가 편차를 줄인다.
- 코딩테스트에 AI 활용 과정(프롬프트, 검증, 디버깅)까지 평가 항목으로 포함해 실무에서 요구되는 "AI를 올바르게 쓰는 능력"을 함께 측정한다.
- 면접 평가는 지원자에게도 공개해 피드백으로서의 가치를 제공하고, 코딩테스트의 세부 평가 근거는 채용담당자만 열람해 평가 근거의 오남용·외부 유출을 막는다.
- 최종 채용 결정은 반드시 사람이 내리도록 해 AI 평가의 오남용·과신을 구조적으로 막는다.

3. 타깃 사용자

사용자	설명	주요 목표
지원자(구직자)	공개 공고를 보고 지원하는 외부 사용자	공고 탐색 → 지원 → AI 면접 → 코딩테스트 응시 → 지원현황 및 면접 평가 확인
기업 관리자(채용담당자)	조직에 소속된 내부 사용자	공고 작성·관리 → 질문/가중치/코딩테스트 설정 → 지원자 심사(평가결과 전체 열람) → 최종 채용 결정

관리자 계정의 초대/승인 기능은 MVP 범위에서 비활성화한다(4.1, 9장 참조). 운영자(모델·정책 관리, 장애 대응) 역할은 이번 범위에서 관리자 역할에 포함하며, 세부 운영 권한 분리는 TRD에서 다룬다.

4. 핵심 기능

1. 공개 채용공고 탐색 및 지원
2. 로그인/회원가입 및 복귀 경로 보존 (`returnTo`)
3. 이력서 등록(PDF 업로드 또는 직접 작성) 및 확인
4. AI 모의면접: TTS 질문 제시 → STT 답변 전사 → 템플릿/RAG 기반 질문 생성 → 근거 기반 꼬리질문 (기본 10문항, 꼬리질문은 해당 기본 문항에 포함되며 면접 전체 최대 4개), **동시 응시 상한 적용(v1.3)**
5. 코딩테스트(면접 완료 후, **공고별 체크박스로 선택 적용**): 코드 에디터 + 자체 호스팅(온프레미스) LLM 채팅 + 격리 실행 환경
6. AI 자동 평가 및 리포트 생성 — **면접 평가(점수/피드백)는 지원자에게 공개**, **코딩테스트는 응시 중 실행 오류 여부 + 제출 후 정답 일치 여부만 공개(v1.3)**, 세부 평가·근거는 관리자 전용
7. 관리자 대시보드: 공고관리, 지원자관리, 질문·가중치 설정, 일정/알림, 직무별 통계

8. 공고 자동 생성(AI) — 관리자가 몇 가지 질문(선택형+단답형)에 답하면 AI가 공고 초안 생성, **차별 표현 주의 표시(v1.3)** (10장)
9. 비동기 일정/알림 (지원 마감 리마인더, 면접 일정 통보, 메일 발송) + **평가 완료 사이트 내 알림(v1.3)**

4.1 관리자 계정 생성 (MVP 범위)

- 관리자 초대/승인 플로우는 **이번 버전에서 비활성화**한다. 관리자 계정은 운영자가 직접 발급하는 방식으로 임시 운영한다.
- 조직 내 관리자가 다른 관리자를 초대하고 승인하는 기능은 후속 버전 과제로 남긴다.

5. 사용자 흐름

5.1 지원자 흐름

```
공개 공고 목록 → 공고 상세 → 지원하기
  → (미로그인) 로그인/회원가입 모달 → 인증 성공 → 해당 공고 지원 흐름으로 복귀
  → 개인정보 동의(평가 결과 공개 범위 조항 포함) → 이력서 확인/등록 → 지원 접수
  → 마이크/카메라 환경 점검
  → [면접 시작하기] → (동시 응시 상한 초과 시) "이미 많은 면접자들이 면접 중입니다. 추후 다시 요청해주세요."
→ 나중에 마이페이지에서 다시 시작
  → AI 모의면접 응시(기본 10문항, 꼬리질문은 해당 기본 문항에 포함되며 면접 전체 최대 4개) → 면접 완료
  → (공고에 코딩테스트 체크된 경우) 코딩테스트 응시 → 제출
  → 평가 완료 시 상단 알림 아이콘으로 사이트 내 알림 수신
  → 마이페이지에서 지원현황 확인
    - 면접: 평가 완료 시 점수와 AI 피드백(강점/개선점) 확인 가능
    - 코딩테스트: 채점 완료 시 "테스트 정답을 맞히셨습니다 / 맞히지 못했습니다"만 확인 가능(세부 평가는 비공개)
    - 최종 합격/불합격/보류 통지 확인
```

- 로그인 복귀 규칙: 상단 로그인으로 들어오면 공고 목록으로, "지원하기"를 누르다 로그인했으면 해당 지원 절차로, 관리자 계정으로 로그인하면 관리자 대시보드로 이동한다. `returnTo`는 허용된 내부 경로만 검증한다.
- **진행 순서는 "AI 면접 → 코딩테스트"로 고정**한다. 공고별 순서 변경 기능은 제공하지 않는다(v1.3 확정).

5.2 관리자 흐름

```
관리자 로그인/권한 확인 → 대시보드
  → 공고 관리: 작성/수정(공고 자동 생성 버튼 포함) → 코딩테스트 포함 여부 체크박스 → 미리보기 → 게시/마감
  → 지원자 관리: 공고별 목록 → 지원자 상세(이력서/면접답변/코딩테스트 결과/AI 평가 전체) → 최종 채용 결정
  → 질문 설정: 수동 입력 또는 질문은행에서 자동 선택, 유형별 문항 수/평가 가중치 설정
  → 일정/알림: 캘린더 관리, 통보 메일 발송 이력 확인
  → 직무별 통계 조회
```

6. 기능 요구사항

6.1 로그인/회원가입 및 복귀 경로

- 미로그인 사용자가 "지원하기"를 클릭하면 로그인/회원가입 모달을 띄우고, 인증 성공 시 원래 하려던 지원 절차(`jobId` 보존)로 복귀한다.
- 신규 가입 시 이력서 등록 또는 건너뛰기를 선택할 수 있다.
- 관리자 계정으로 지원자 전용 기능(지원하기 등)에 접근하면 "지원자 권한 필요" 안내를 표시하고 차단한다.
- `returnTo`는 화이트리스트 기반 내부 경로만 허용해 오픈 리다이렉트를 방지한다.
- 관리자 계정은 초대/승인 절차 없이 운영자가 직접 발급한다(4.1절).

6.2 공고 탐색 및 지원

- 지원자는 비로그인 상태에서도 공고 목록/상세를 열람할 수 있다.
- 직무 필터·검색을 제공한다.
- 동일 공고에 중복 지원을 방지한다.
- 이력서가 이미 있으면 기존 이력서를 확인/수정, 없으면 PDF 업로드 또는 직접 작성 후 추출 결과를 확인/정정할 수 있어야 한다.

6.3 AI 모의면접

- 면접 시작 전 마이크/카메라 권한 확인 및 장치 점검을 거친다.
- 질문은 텍스트 표시와 동시에 TTS로 재생하며, TTS 종료 후 3-2-1 카운트 뒤 녹음을 시작한다.
- 답변은 제한시간 또는 제출 시점에 저장되고 STT로 전사된다. 전사 품질이 낮으면 재녹음/확인 요청으로 처리한다.
- **문항 수**: 기본 문항은 **10개 고정**이며, 유형별 분배는 인성 2 / 자소서 관련 2 / 기업 관련 2 / 직무 관련 4이다. 답변의 논리적 모순·모호함이 감지되면 꼬리질문이 기본 문항에 **추가로** 붙으며, 꼬리질문은 면접 전체에서 **최대 4개**까지 허용한다. **꼬리질문은 별도 문항으로 세지 않고 꼬리질문을 만든 기본 문항에 포함한다(v1.3).** 따라서 면접의 문항 수는 항상 10개이고, 답변 횟수만 최대 14회(10 + 4)까지 늘어난다.
- **문항 점수(v1.3)**: 기본 답변과 그 꼬리질문 답변의 루브릭 점수를 항목별로 평균 내 문항당 점수 1개를 낸다. 진행 표시는 기본 문항 번호("3 / 10")를 쓰고, 꼬리질문은 같은 번호에 "꼬리질문" 표시만 붙인다.
- 유형별 기본 문항 수와 꼬리질문 상한(기본값 4)은 관리자가 공고별로 조정할 수 있는 설정값으로 둔다.
- 질문은 관리자 수동 입력, 질문은행 선택, 기업 문서 기반 RAG 생성 중 하나로 공급되며, 실제 출제된 질문은 변경 불가 스냅샷으로 저장한다.
- 답변의 논리적 모순·모호함이 감지되고 꼬리질문 누적 개수가 4개 미만이면 근거 기반 꼬리질문을 생성한다. 4개에 도달하면 더 이상 꼬리질문을 생성하지 않고 다음 기본 질문으로 진행한다.
- 꼬리질문 생성이 지연되면(기준 시간은 TRD에서 정함) 꼬리질문을 건너뛰고 다음 기본 질문으로 진행해 면접이 멈추지 않게 한다(v1.3).
- 면접 상태는 `NOT_STARTED/READY/IN_PROGRESS/INTERRUPTED/SUBMITTED/TERMINATED/REPORT_PENDING/REPORT_READY/FAILED`로 관리한다(v1.3: `TERMINATED` 추가).
- **세션 재개**: 네트워크 중단 등으로 면접이 중단되면(`INTERRUPTED`), 마지막 저장 상태를 기준으로 **이어서 진행**할 수 있다. 처음부터 재응시하지 않는다.

- **화면 이탈 강제 종료(v1.3 확정)**: 면접 중 다른 화면으로 3초 넘게 이동하면 면접을 종료하고 `TERMINATED`로 기록한다. 재개 대상이 아니며 코딩테스트로 진행하지 않는다. 그때까지 답한 문항만 평가하고, 답하지 않은 기본 문항은 0점으로 총점에 반영한다(문항 수는 기본 10문항 기준). 시스템 오류로 인한 실패(`FAILED`)와 구분한다.
- **동시 응시 상한(v1.3 신규)**: 모든 AI 처리를 사내 GPU 한 대로 하므로 동시에 진행되는 면접 수에 상한을 둔다(기본값은 TRD에서 정함). 상한을 넘은 상태에서 "면접 시작하기"를 누르면 면접을 시작하지 않고 **"이미 많은 면접자들이 면접 중입니다. 추후 다시 요청해주세요."**를 안내한다. 지원자는 나중에 마이페이지에서 면접을 다시 시작할 수 있다. 서버는 예상 대기 시간을 계산해 응답에 포함하되, 화면 표시는 후속 버전에서 결정한다.

6.4 코딩테스트 (면접 완료 후, 공고별 선택 적용)

- 진행 순서는 **"AI 면접 → 코딩테스트"로 고정**이며, 관리자는 공고관리 화면에서 코딩테스트 포함 여부를 **체크박스**로 설정할 수 있다. 체크 해제된 공고는 코딩테스트 단계를 건너뛴다.
- LLM은 **자체 호스팅(온프레미스)으로 확정**한다. 외부 LLM API는 사용하지 않는다.
- 응시자는 코드를 직접 작성하거나 온프레미스 LLM 채팅 패널에 질문할 수 있다. AI 사용 자체는 감점 사유가 아니다.
- LLM 질문은 허용/보완 요청/반려로 분류되며, 반려되어도 시험 토큰 예산은 공지된 정책에 따라 차감될 수 있으나 실제 모델 사용량과는 별도로 기록한다.
- 시스템 오류·안전필터 오탐으로 반려된 경우 예산을 복원하고 감점하지 않는다.
- **중간 체크(v1.3 확정)**: 응시 중 "실행"을 누르면 격리 환경에서 코드를 실행하고, 실행 오류(문법 오류, 예외, 시간 초과, 메모리 초과) 없이 끝났는지를 **"정상 작동 / 비정상 작동"**으로 보여준다. 실행 출력과 오류 메시지는 디버깅을 위해 함께 보여준다. 이 단계에서는 정답 일치 여부를 판정하지 않는다.
- **최종 체크(v1.3 확정)**: 제출된 코드는 변경 불가 스냅샷으로 저장되고, 격리된 실행 환경에서 전체 테스트(공개+비공개)를 수행한다. 모든 테스트의 출력이 정답과 일치하면 **"테스트 정답을 맞히셨습니다"**, 하나라도 다르거나 실행 오류가 나면 **"테스트 정답을 맞히지 못했습니다"**로 판정한다. 통과한 테스트 개수 등 세부 내용은 공개하지 않는다.
- 시험 토큰이 소진되어도 코드 편집·실행·제출은 계속 허용한다.
- 반려 누적에 따른 감점은 "프롬프트 및 AI 활용 판단(15점)" 항목 내 최대 3점으로 제한하며, 자동 산정값은 확정 점수가 아니라 관리자 검토 대상이다(1회 0점 / 2회 0.5점 / 3회 1.5점 / 4회 2.5점 / 5회 이상 최대 3점, 누적).
- **토큰 예산/반려 정책의 구체적인 수치(예: 반려 시 차감량)는 이번 버전에서 확정하지 않으며, 실제 운영 전 모의시험을 통해 검증한다**(9장).
- 실제 정답·비공개 테스트 내용은 어떤 경우에도 LLM 프롬프트나 검색 문서, 지원자 화면에 노출하지 않는다.

6.5 평가 및 리포트

- 면접 평가는 고정 루브릭(논리성/전달력/전문성/내용 관련성)으로 질문별 채점 후 공고별 버전 고정 가중치로 합산한다.
- **평가 처리 시간 단축(v1.3)**: 답변이 확정될 때마다 해당 문항을 미리 평가해 두어, 면접 종료 후에는 마지막 문항과 종합 피드백만 처리한다(세부 방식은 TRD).
- **강제 종료 면접의 평가(v1.3)**: 답한 문항만 평가하고, 답하지 않은 기본 문항은 0점으로 총점에 넣는다. 기본 답변을 마친 문항은 꼬리질문에 답하기 전에 종료되었더라도 "답변함"으로 세고, 기본 답변만으로 평가한다(꼬리질문 미응답은 감점하지 않음). 지원자 화면과 관리자 화면에 "강제 종료로 10문항 중 N

문항만 평가되었습니다"를 표시하고, 관리자 화면에는 "답변 문항 기준 평균"을 참고값으로 함께 보여준다.
- 코딩테스트 평가는 정확성 40 / 코드 품질 20 / 검증·디버깅 20 / 프롬프트·AI 활용 판단 15 / 설명·근거 5(합계 100, 초안)로 산출한다.
- 면접 점수와 코딩테스트 점수는 별도로 기록하고, 관리자 화면에서 통합 조회할 수 있다.
- AI 평가 결과에는 근거 인용과 신뢰도/검토 필요 표시를 포함한다.
- **평가 결과 공개 범위 (v1.3 변경)**:
- **AI 모의면접**: 항목별 점수와 AI 피드백(강점/개선점)을 평가 완료(`REPORT_READY`) 시점에 **지원자에게 공개**한다. 단, 평가 근거 인용 원문과 신뢰도/검토 필요 표시는 관리자 전용으로 유지한다.
- **코딩테스트**: 지원자에게는 **응시 중 실행 오류 여부(정상 작동/비정상 작동)**와 **제출 후 정답 일치 여부(맞힘/못 맞힘)**만 공개한다. 통과 테스트 개수, 정확성/코드품질/검증·디버깅/프롬프트 활용 판단 등 세부 점수와 근거는 **관리자만 열람**한다.
- 지원자는 마이페이지에서 위 공개 범위에 해당하는 내용과 최종 채용 결과(합격/불합격/보류) 통지를 확인할 수 있다.
- **평가 완료 알림(v1.3 신규)**: 면접 평가(`REPORT_READY`)나 코딩테스트 채점이 끝나면 지원자에게 **사이트 내 알림**을 보낸다. 메일은 보내지 않는다.
- 최종 채용 여부(합격/불합격/보류)는 AI가 자동 결정하지 않고 관리자가 결정하며, 결정·통지 이력을 기록한다.

6.6 관리자 공고/질문/평가 관리

- 공고 작성/수정, 임시저장/템플릿, 지원자 화면 미리보기, 게시/마감/삭제 정책을 제공한다.
- 질문은 수동 입력 또는 빈 슬롯 자동 선택으로 구성하고, 유형별 문항 수와 제한시간을 설정할 수 있다.
- 평가 항목별 가중치를 공고 단위로 설정할 수 있다.
- 캘린더에서 면접 일정을 추가/수정할 수 있다.
- 직무별 통계를 상세히 조회할 수 있다.

6.7 비동기 일정/알림

- 지원 마감 임박 시 미완료 지원자에게 리마인더를, 공고 마감 하루 전 관리자에게 알림을 발송한다.
- 일정 생성/변경 시 수락/조율 링크를 포함한 통보를 발송한다.
- 발송 실패 시 재시도하며, 중복 발송은 방지한다.
- **사이트 내 알림(v1.3 신규)**: 지원자 화면 상단에 알림 아이콘과 읽지 않은 알림 개수를 표시한다. 평가 완료 알림은 사이트 내 알림으로만 보낸다. 위의 리마인더·일정 통보는 기존대로 메일로 보낸다.

6.8 공고 자동 생성

10장에서 상세 설계와 리스크를 다룬다.

7. 비기능 요구사항

7.1 성능 (초안 — 부하테스트 전 확정값 아님)

- API 응답 목표: 일반 API p95 300ms 이내(초안). 실제 목표치는 동시 사용자 수 확정 후 조정한다.
- LLM 추론·STT/TTS·코드 실행은 동기 API 요청과 분리된 큐/워커에서 처리한다.

- **평가 처리 시간 목표(v1.3)**: 면접 종료 후 평가 완료까지 대기열이 비어 있으면 약 3분 이내, 다른 면접이 몰려도 약 10분 이내를 목표로 한다(추정, PoC로 확정).
- **온프레미스 AI 현재 제약**: 현재 개발/시험 환경의 GPU는 VRAM 6GB이다. 이 GPU에 소형/경량 양자화 LLM 1종을 올려 면접·코딩테스트·평가·공고 생성이 함께 쓰고, STT/TTS는 CPU로 처리한다. 이 환경에서 원활한 동시 면접은 1~2명 수준으로 예상되어 동시 응시 상한을 둔다(6.3). **실무(실제 서비스) 환경에서는 더 큰 GPU로 확장 가능**하며, 모델 크기·동시성·응답 속도 목표는 확장된 하드웨어 기준으로 재산정한다.
- MVP 기준: 코딩테스트 언어 1종, 실행 동시성 제한.

7.2 보안

- 모든 통신 HTTPS, 비밀번호는 Argon2 등 안전한 해시로 저장한다.
- 서버 측 RBAC 및 조직 범위(`organization_id`) 검증을 모든 API/쿼리에 적용한다(화면 숨김만으로 대체하지 않는다).
- `returnTo`는 오픈 리다이렉트 방지를 위해 내부 경로만 허용한다.
- 면접 음성/대화 전사, 코딩테스트 채팅 내용 등 개인정보가 포함될 수 있는 데이터는 접근통제·암호화·감사 로그를 적용한다.
- **평가 데이터 접근 제어 (v1.3 변경)**: 면접 평가 점수·AI 피드백과 코딩테스트 정답 일치 여부는 지원자 본인에게 공개 API로 제공한다. 코딩테스트 세부 평가(점수·근거·통과 테스트 개수)와 평가 근거 원문·신뢰도 표시는 관리자 권한을 가진 사용자만 조회 가능하도록 접근 제어한다(지원자 본인도 조회 불가).
- 코드 실행 환경은 네트워크 차단, CPU/메모리/시간 제한, 비특권 사용자, 임시 파일 정리, 동시성 제한을 적용한다.
- 코딩테스트 LLM에는 정답·비공개 테스트·숨은 채점 기준을 절대 노출하지 않는다.

7.3 안정성

- **세션 재개**: 면접/코딩테스트 세션 중 네트워크가 중단되면 마지막 저장 상태를 기준으로 이어서 진행할 수 있도록 지원한다. 처음부터 다시 시작하지 않는다.
- 토큰 원장(예산 차감/복원), 평가 변경 등 민감한 상태 변경은 append-only 이벤트로 기록하고 삭제하지 않는다.
- 동일 요청 ID의 중복 전송은 멱등 처리한다.
- 비동기 작업(리포트 생성, 메일 발송, 평가)은 재시도와 상태 추적(`status`, `attempts`, `error_code`)을 갖춘다.

7.4 개인정보/공정성

- 이력서·음성·대화·코드 데이터는 목적별 수집·고지·동의를 거치고 보존기간·삭제 절차를 둔다.
- **개인정보 활용 동의서에 다음 내용을 명시해 지원자에게 사전 고지한다(v1.3 변경)**: "AI 면접의 평가 결과(점수, AI 피드백)는 본인에게 공개됩니다. 면접 중 다른 화면으로 3초 넘게 이동하면 면접이 종료되며, 답하지 않은 문항은 0점 처리됩니다. 코딩테스트는 응시 중 실행 오류 여부와 제출 후 정답 일치 여부만 공개되며, 세부 평가 점수와 근거는 채용담당자에게만 제공됩니다. 모든 AI 처리는 Huge의 자체 서버에서 이뤄지며 외부 AI 서비스로 전송되지 않습니다."
- 시선/감정/음성 특성만으로 부정행위나 성격·적합성을 단정하지 않는다.
- 코딩테스트 LLM 함정 시나리오는 난이도·노출·모델 버전을 고정하고 사전 QA를 거쳐 공정성을 검증한다.

- 지원자에게는 AI가 불완전하거나 틀린 답을 줄 수 있다는 점과 감점 정책을 사전에 고지한다.

7.5 개발 환경 요구사항 (정확한 버전 고정은 TRD에서 확정)

- 백엔드: Python 3.12 기반 venv, FastAPI + Pydantic 2, SQLAlchemy 2 + Alembic
- DB: PostgreSQL 17 + pgvector 확장
- 비동기 처리: Redis + Celery
- AI 오케스트레이션: LangChain 1.x + LangGraph 1.x
- 프런트엔드: Next.js 16 / React 19 / TypeScript, 코드 에디터는 Monaco Editor
- 온프레미스 LLM 서빙: Ollama(MVP, GPU 6GB 환경 기준 소형 양자화 모델 1종을 모든 LLM 기능이 공유) — 실무 환경 확장 시 vLLM 및 더 큰 모델 검토
- 온프레미스 STT/TTS(v1.3): STT는 faster-whisper(CPU), TTS는 CPU 실행 가능한 한국어 엔진(PoC로 선정)
- 코드 실행: 격리된 컨테이너 또는 마이크로VM 기반 실행기
- 실제 설치 목록·버전 고정은 TRD의 기술 스택 절을 따른다.

8. 성공 지표

- **엔드투엔드 완결성**: 지원 → AI 면접 → 코딩테스트 → 평가 리포트 → 관리자 심사 → 채용 결정까지 중단 없이 흐르는 비율
- **면접 단계 오류율**: STT 전사 실패/재녹음 발생률, 세션 중단율, 중단 후 재개 성공률, 꼬리질문 생략률(지연으로 인한 생략, v1.3)
- **동시 응시 상한 도달률(v1.3 신규)**: "면접 시작하기" 시도 중 상한 초과로 거절된 비율 — 높으면 하드웨어 확장 신호로 본다
- **코딩테스트 공정성**: LLM 함정 시나리오가 의도대로 작동(응시자가 오류를 발견·수정하는 비율), 오탐 반려 발생률
- **평가 리포트 처리 시간**: 면접/코딩테스트 제출 후 리포트 `REPORT_READY` 까지 소요 시간
- **관리자 심사 효율**: 지원자 1명당 관리자 심사 소요 시간(AI 평가 도입 전후 비교)
- **지원자 피드백 만족도**: 면접 평가 공개 후 지원자의 피드백 품질 체감도(설문 등으로 측정)
- **공고 자동 생성 활용도**: 자동 생성 기능 사용률, 생성 후 관리자 수정 비율(과도한 수정이 필요하면 품질 문제로 간주), 차별 표현 경고 발생률(v1.3)

9. 남아 있는 미확정 항목

항목	현황	비고
코딩테스트 토큰 예산·반려 정책의 구체 수치	방향(반려해도 예산 차감, 오탐은 복원)은 확정, 정확한 차감량·감점 임계값은 미정	실제 운영 전 모의시험으로 검증 후 확정
온프레미스 LLM 모델 종류/크기	자체 호스팅으로 확정, 모든 LLM 기능이 모델 1종을 공유. 구체 모델은 미정(GPU 6GB 제약 내에서 선정)	PoC로 선정. 실무 확장 시 더 큰 GPU 기준으로 재선정
STT/TTS 모델 선정	**온프레미스로 확정(v1.3)**. STT는 faster-whisper 모델 크기, TTS는 엔진 미정	PoC로 한국어 품질·CPU 속도 비교 후 확정
동시 면접 상한 값	상한을 두는 것은 확정(v1.3), 값은 미정	PoC 부하 측정 후 확정
예상 대기 시간 화면 표시	서버 계산만 확정(v1.3), 표시 여부·위치 미정	후속 버전

항목	현황	비고
관리자 초대/승인 활성화 시점 및 세부 절차	MVP에서는 비활성화로 확정	활성화할 후속 버전에서 절차 설계 필요

10. 추가 제안 기능: 공고 자동 생성

CLAUDE.md 추가 요구사항에 명시된 기능으로, 근거 문서 3종에는 없는 신규 플로우라 직접 설계했다.

10.1 흐름

```
관리자: 공고 관리 화면에서 "공고 자동 생성" 버튼 클릭
  → 질문 응답(선택형 + 단답형 혼합)
     - 선택형: 직무, 경력 연차, 고용 형태 등 — 드롭다운/버튼 선택
     - 단답형: 회사 상황 등 — 짧은 한두 줄 입력(긴 자유 서술 textarea 대신)
     - 코딩테스트 필요 여부 — 체크박스
  → AI가 공고 초안 생성(제목/설명/자격요건/우대사항, 코딩테스트 체크박스 자동 세팅)
  → 관리자 검토(미리보기) 화면에서 확인·편집 — 차별 소지 표현은 밑줄 + 경고로 표시(v1.3)
  → 게시
```

10.2 기능 요구사항

- **입력 방식**: 모든 항목을 자유 서술로 받지 않는다. 직무/경력/고용형태처럼 정형적인 항목은 선택형(드롭다운, 버튼 선택)으로 받고, 회사 상황처럼 서술이 필요한 항목만 짧은 단답형 입력(1~2줄)으로 받아 작성 부담을 줄인다.
- 자동 생성은 초안 생성까지만 수행한다. 게시 버튼 자체를 막지는 않지만, **검토를 건너뛰고 바로 게시하려 할 때 주의 메시지(예: "AI 생성 초안을 검토하지 않았습니다. 그대로 게시하시겠습니까?")를 표시**해 관리자가 인지하도록 한다. 게시를 강제로 차단하지는 않는다.
- 코딩테스트 필요 여부 질문에 대한 답은 6.4절의 공고별 **체크박스** 기본값으로 반영한다.
- **차별 표현 주의 표시(v1.3 신규)**: 미리보기 화면에서 연령·성별·혼인 여부·출신 지역·신체 조건 등 차별 소지가 있는 표현에 **밑줄과 경고 문구**를 표시한다. 금지어 사전(규칙) 기반으로 찾으며, 게시를 차단하지 않고 주의만 준다.
- 생성 이력(입력 질문/답변, 생성된 초안, 모델 버전, 차별 표현 경고 내역)을 기록해 추후 품질 검증에 활용한다.

10.3 장점

- 비전문 관리자도 일관된 형식·품질의 공고를 빠르게 작성할 수 있다.
- 공고 작성 소요 시간을 줄인다.
- 선택형+단답형 혼합 입력으로 자유 서술에 대한 부담을 낮춰 입력 완료율을 높인다.

10.4 리스크 및 대응

- **사실과 다른 내용 생성(hallucination)**: 회사 상황 입력이 부실하면 근거 없는 내용이 들어갈 수 있다 → 관리자 검토 단계를 권장하고 검토 여부를 추적한다.
- **차별적/법적 문제 문구 포함 가능성**: 자격요건 작성 시 연령·성별 등 차별적 표현이 생성될 수 있다 → **미리보기에서 밑줄 + 경고로 주의를 준다(v1.3 확정)**. 사전 기반이라 사전에 없는 표현은 놓칠 수 있고

(예: "패기 넘치는 사회초년생"), 정상 표현에 경고가 뜰 수도 있으므로(예: "여성 의류 브랜드 MD") 차단하지 않고 관리자 판단에 맡긴다.

- **과신으로 인한 검토 생략**: 관리자가 초안을 그대로 게시할 위험 → **게시를 차단하지 않고, 검토 전 게시 시도 시 주의 메시지만 노출**한다.