Huge TRD — AI 모의면접 채용 플랫폼 v1.0



> **Huge** · AI가 함께하는 더 나은 채용의 시작 — Good People, Great Teams 제작 · **AIIT** (AI Interview Training) 작성일: 2026-10-26 · 문서 종류: TRD(Technical Requirements Document, 기술 요구사항 정의서)
>
> 근거 문서 (우선순위 순) 1. PRD v1.3 — `AI채용플랫폼_PRD_v1.3/PRD_AI채용플랫폼_v1.3.md` (기능 요구사항의 확정 출처) 2. 화면정의서 v1.3 — `AI채용플랫폼_화면정의서_v1.3/화면정의서_AI채용플랫폼_v1.3.md` (화면·상호작용의 확정 출처) 3. 기술 아키텍처 v1.0 — `AI 기술 아키텍처v1.0/AI채용플랫폼_기술아키텍처_v1.0/기술아키텍처_통합설계_v1.0.md` (v0.7을 이 TRD의 결정 D1~D10에 맞춰 갱신, 절 번호 동일) 4. 코딩테스트 v0.6 — `AI채용플랫폼_코딩테스트_v0.6/` (플로우 09~13, 설계 및 평가기준) 5. Mermaid v0.4 — `AI채용 플랫폼 Mermaid v0.4/` (플로우 01~07) 6. 브랜드 자산 — 원본 `AI 채용을 돕는 휴지곽 로봇 Huge.png`, `메인로고.png`, `글씨만 있는 로고.png` / 웹용 가공본 `brand/`

---

0. 이 문서를 읽는 방법

PRD가 **"무엇을 만들 것인가"**라면 TRD는 **"그것을 어떤 기술로, 어떤 조건에서, 어디까지 만들 수 있는가"**를 정한다. 각 요구사항은 `TR-영역-번호` 형식의 ID를 가지며, 구현할 때 테스트 케이스 이름과 연결한다(SDD/TDD 원칙, 11장).

표기	의미
[확정]	PRD/화면정의서/이번 의사결정으로 확정된 내용
[제안]	TRD 작성자가 기술 판단으로 제안한 기본값. 이견이 없으면 이 값으로 구현
[미결정]	운영 전 PoC/모의시험/회의로 정해야 하는 항목 (12장에 모음)
[추정]	실측 전 추정치. PoC로 반드시 측정해서 교체

0.1 TRD v1.0 작성 시 의사결정 기록 (2026-10-26)

문서 간 모순·공백에 대해 사용자에게 확인하고 정한 내용이다.

#	쟁점	결정	영향
D1	면접 질문생성·평가·공고 자동생성 LLM, STT/TTS의 배치 (PRD 9장 미정)	**전부 온프레미스.** 외부 AI API를 쓰지 않는다	GPU 6GB 한 대를 모든 LLM 작업이 같이 쓴다 → 우선순위 큐와 동시성 제한 필요 (4.4, 9.1)

#	쟁점	결정	영향
D2	화면 이탈 3초 강제 종료 상태값 (화면정의서 A7이 TRD에 위임)	**신규 상태 `TERMINATED` + 답변한 문항만 부분 평가**	상태 머신·리포트·마이페이지 분기 변경(5.3, 7.3)
D3	면접/코딩테스트 순서 변경 가능 여부 (PRD 5.1 ↔ 화면정의서 B3/A8)	**"면접 → 코딩테스트"로 고정. PRD 문구 수정**	PRD 5.1 문장 수정 완료. `jobs`에 순서 컬럼을 두지 않는다
D4	코딩테스트 공개 결과의 판정 기준 (어느 문서에도 없음)	**2단계로 판정.** 응시 중 중간 체크 = 실행 오류 여부(정상/비정상 작동), 제출 후 최종 체크 = 정답 일치 여부("테스트 정답을 맞히셨습니다 / 맞히지 못했습니다")	7.5, 7.9. PRD v1.3 §6.4·6.5에 반영
D5	동시 면접 상한 초과 시 처리 (추천 R1)	**대기열 없이 거절 안내.** "이미 많은 면접자들이 면접 중입니다. 추후 다시 요청해주세요." 예상 대기 시간은 서버가 계산해 응답에 넣고, 화면 표시는 후속	TR-AI-23, 화면정의서 v1.3 A6
D6	평가 완료 알림 (추천 R2)	**메일이 아닌 사이트 내 알림.** 동시에 평가 지연 원인을 분석해 처리 시간을 줄인다	4.5, TR-NOTI-06, 화면정의서 v1.3 C1
D7	공고 차별 표현 (추천 R3)	**미리보기에서 밑줄 + 경고. 게시 차단 없음**	TR-GEN-08
D8	마스코트 일러스트 (추천 R4)	**이미지 크롭·최적화 후 화면에 사용**	9장, `brand/`
D9	강제 종료 면접의 총점	**안 답한 문항 0점 (확정, 변경 여지 없음).** 지원자에게도 0점 반영 총점 + 안내 문구로 공개(PRD 공개 범위 규칙 그대로)	TR-IV-61, 62
D10	면접 문항 수를 세는 단위 (안내 문구 "N문항 중 M문항", 진행 표시)	**기본 10문항 기준.** 꼬리질문은 자신을 만든 기본 문항에 포함한다(면접 전체 최대 4개). 진행 표시 `3/10`, 강제 종료 안내 "10문항 중 N문항". 문항 점수 = 기본·꼬리 답변 루브릭 항목별 평균, 꼬리질문 직전 종료 시 기본 답변만으로 평가(감점 없음)	TR-IV-60, 63, 화면정의서 A7/A11/B6

0.2 이전 문서에서 이어받은 모순 해결

- 코딩테스트 v0.6의 "코딩테스트 → 면접" 서술은 PRD를 따라 **"면접 → 코딩테스트"**로 대체한다(화면정의서 v1.0부터 유지).
- 기술 아키텍처 v0.7의 "10문항 vs 12문항 미결정"은 PRD v1.2의 **기본 10문항 + 꼬리질문 최대 4개**로 확정한다. 꼬리질문은 해당 기본 문항에 포함하므로 문항 수는 10개다(D10).
- 기술 아키텍처 v0.7의 "관리자 초대/승인"은 PRD 4.1에 따라 **MVP에서 비활성화**한다(운영자 직접 발급).

---

1. 기술 개요

1.1 시스템의 기술적 목표

1. **엔드투엔드 흐름 완결**: 공개 공고 → 지원 → 이력서 → AI 음성 면접 → (선택) 코딩테스트 → 비동기 평가 → 관리자 심사 → 사람의 최종 결정이 끊기지 않고 이어진다.
2. **AI를 전부 사내에서 운영(D1)**: 지원자 음성·답변·코드·채팅이 외부 AI 서비스로 나가지 않는다.

3. **제한된 GPU(6GB)로도 동작**: 무거운 작업(LLM·STT·TTS·코드 실행)을 웹 요청에서 떼어 큐로 보내고, 실시간 작업이 배치 작업보다 먼저 처리되게 한다. 느려지면 기능을 줄여서라도(꼬리질문 생략 등) 면접 흐름은 멈추지 않게 한다.
4. **재현 가능한 평가**: 질문·루브릭·가중치·모델·프롬프트·시나리오 버전을 세션 시작 시 고정해 같은 조건으로 다시 볼 수 있게 한다.
5. **공개 범위를 서버가 강제**: 지원자용·관리자용 응답 스키마를 나눠서, 관리자 전용 데이터는 지원자 API 응답에 아예 들어가지 않게 한다.

1.2 범위

포함 (MVP)	제외 (후속)
지원자 화면 A1~A11, 관리자 화면 B1~B11	관리자 초대/승인 (PRD 4.1)
음성 면접 (TTS/STT, 꼬리질문, 재개, 강제 종료)	장애인 대체 응시 트랙 (화면정의서 A6 각주)
코딩테스트 Python 1종	코딩테스트 다중 언어
공고 자동 생성	면접/코딩테스트 순서 변경 (D3)
비동기 평가·알림·통계	영상 분석 (시선/감정) — PRD 7.4에 따라 하지 않음

---

2. 기술 스택

2.1 스택 요약

계층	기술	버전 기준	역할
언어(백엔드)	Python	**3.12.x** [확정, PRD 7.5]	API·워커·AI 파이프라인
웹 API	FastAPI + Pydantic 2 + Uvicorn	FastAPI ≥0.115 / Pydantic 2.x	인증, 업무 로직, 세션 상태
ORM/마이그레이션	SQLAlchemy 2.0 + Alembic	2.0.x / 1.x	DB 접근, 스키마 버전 관리
DB	PostgreSQL + pgvector	**17** / pgvector 0.8.x	관계형 데이터 + 임베딩 검색
큐/캐시	Redis + Celery (+ Celery Beat)	Redis 7.x / Celery 5.x	비동기 작업, 예약 알림
AI 오케스트레이션	LangChain + LangGraph	1.x / 1.x	면접 질문 상태 흐름, RAG
LLM 서빙	**Ollama** (온프레미스)	최신 안정판	모든 LLM 추론 (D1)
STT	**faster-whisper** (CPU, int8)	1.x	답변 음성 전사
TTS	온프레미스 한국어 TTS (PoC 후보: MeloTTS-KR, Piper-KR)	[미결정]	질문 음성 합성
임베딩	sentence-transformers (CPU) — 후보: multilingual-e5-small / bge-m3	[미결정]	RAG 문서·질문은행 벡터화
파일 저장	S3 호환 스토리지 — **MinIO** (개발/사내)	최신 안정판	PDF, 음성, 코드 스냅샷
코드 실행	Docker 컨테이너 격리 실행기 (운영: gVisor `runsc`)	Docker 24+	제출 코드 실행

계층	기술	버전 기준	역할
프런트엔드	Next.js + React + TypeScript	**16 / 19 / 5.x**	전체 화면
폼 검증	React Hook Form + Zod	7.x / 3.x 이상	브라우저 입력 검증
코드 에디터	Monaco Editor (`@monaco-editor/react`)	4.x	코딩테스트 에디터
메일(개발)	Mailpit (SMTP 테스트 서버)	최신	알림 메일 확인
테스트/린트	pytest, ruff / Vitest, ESLint	pytest 8.x / ruff 최신	CLAUDE.md 검증 명령

> **버전 고정 원칙 [확정]**: 위 표는 "메이저(·마이너) 기준"이다. 실제 설치 시점에 정확한 패치 버전을 `requirements.lock`(pip-tools 또는 uv)과 `package-lock.json`에 고정하고, 고정한 파일을 저장소에 커밋한다. 문서에 임의의 패치 버전을 적어두면 설치 시점에 존재하지 않거나 서로 호환되지 않을 수 있기 때문이다.

2.2 백엔드 venv 패키지 목록 (`requirements.in`)

```
# 웹 API
fastapi>=0.115,<1.0
uvicorn[standard]>=0.32
pydantic>=2.9,<3
pydantic-settings>=2.6
python-multipart>=0.0.12
sse-starlette>=2.1            # LLM 스트리밍(SSE)

# DB
sqlalchemy>=2.0.36,<2.1
alembic>=1.14,<2
psycopg[binary]>=3.2,<4
pgvector>=0.3

# 비동기
celery[redis]>=5.4,<6
redis>=5.2

# AI (전부 온프레미스)
langchain>=1.0,<2
langgraph>=1.0,<2
langchain-ollama>=1.0,<2      # 설치 시점에 LangChain 1.x와 호환되는 버전 확인
faster-whisper>=1.1
sentence-transformers>=3.3

# 파일/문서
boto3>=1.35                   # MinIO(S3 호환) 접근
pypdf>=5.1                    # PDF 텍스트 추출

# 보안
argon2-cffi>=23.1             # 비밀번호 해시
itsdangerous>=2.2             # 일정 수락 링크 서명 토큰

# 관측
structlog>=24.4

# 개발/테스트
pytest>=8.3
pytest-asyncio>=0.24
httpx>=0.27                   # FastAPI 테스트 클라이언트
ruff>=0.8
```

> TTS 패키지는 PoC로 엔진을 정한 뒤 추가한다(12장). 엔진에 따라 PyTorch 같은 큰 의존성이 생길 수 있으므로 **TTS 워커는 별도 venv/컨테이너**로 분리한다.

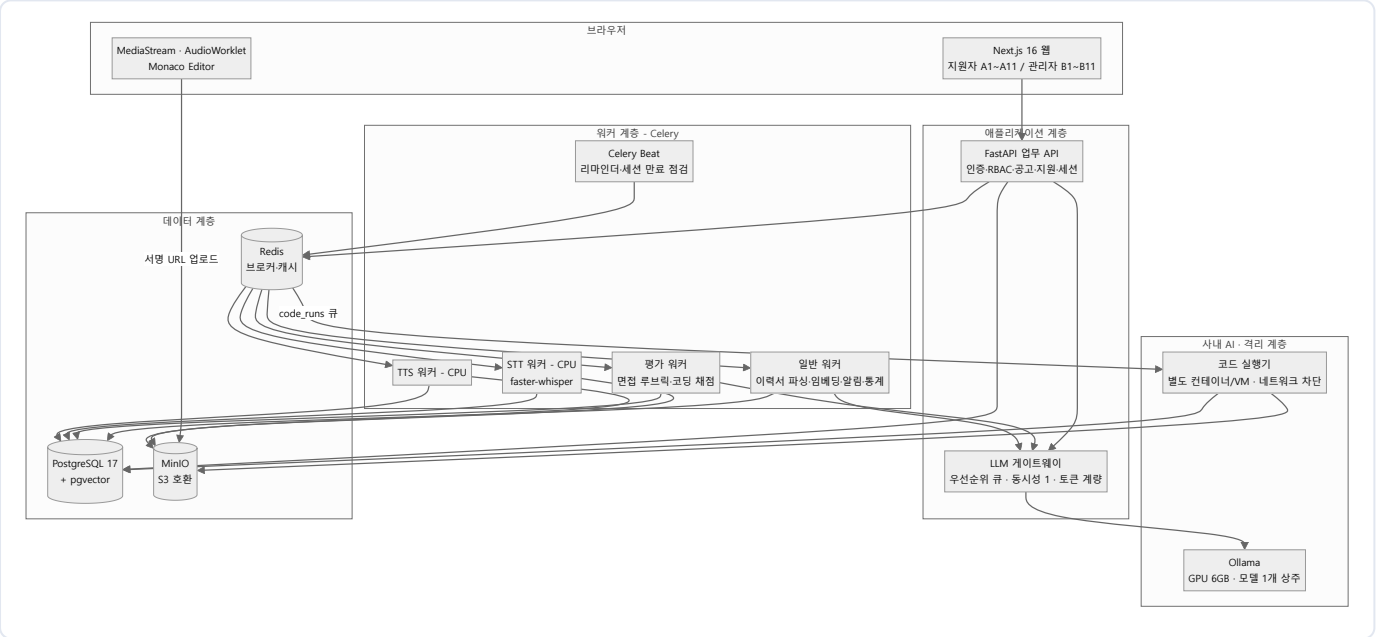
2.3 venv 밖에서 설치해야 하는 프로그램

프로그램	용도	비고
Python 3.12	백엔드	**현재 개발 PC에는 Python 3.10.11이 설치되어 있다** → 3.12 별도 설치 후 venv 생성 필요
Docker Desktop (WSL2 백엔드)	PostgreSQL, Redis, MinIO, Mailpit, Celery, 코드 실행기	Windows에서는 Celery·gVisor를 직접 실행할 수 없으므로 Docker/WSL2로 실행 (10장)
Ollama (Windows 네이티브)	LLM 서빙	Windows에서 GPU를 가장 간단하게 쓰는 방법. API 포트 11434
NVIDIA 드라이버 + CUDA 런타임	Ollama GPU 가속	6GB VRAM
Node.js 22 LTS	Next.js 개발 서버	
ffmpeg	음성 포맷 변환(webm→wav 16kHz)	STT 워커 컨테이너에 포함

---

3. 시스템 아키텍처

3.1 전체 구성도



3.2 배포 단위와 책임 [확정: 아키텍처 v1.0 §13]

#	서비스	실행 위치	핵심 책임	하면 안 되는 것
1	`web` (Next.js)	Node	화면 렌더링, 입력 검증(Zod)	권한 판단 (UI 분기만 함)
2	`api` (FastAPI)	Docker	인증, RBAC, 업무 로직, 상태 전이	STT·LLM·코드 실행을 동기로 처리 (아키텍처 §16)
3	`llm-gateway` (FastAPI 별도 프로세스)	Docker	Ollama 단일 진입점, 우선순위 큐, 토큰 계량, 시나리오 프롬프트 조립	비공개 테스트·정답 테이블 접근 (DB 권한으로 차단, 7.4)

#	서비스	실행 위치	핵심 책임	하면 안 되는 것
4	`worker-general`, `worker-eval`	Docker	파싱·임베딩·평가·알림	코드 실행 (아키텍처 §16)
5	`worker-stt`, `worker-tts`	Docker (CPU)	음성 전사/합성	GPU 사용 (GPU는 LLM 전용)
6	`beat`	Docker	예약 작업	
7	`runner`	**별도 Docker 호스트/VM**	제출 코드 실행	네트워크 접근, Docker 소켓을 api와 공유
8	`postgres`, `redis`, `minio`, `mailpit`	Docker	저장	
9	`ollama`	호스트 네이티브 (GPU)	LLM 추론	

3.3 왜 이렇게 나누는가 (학습 포인트)

- **API와 무거운 작업 분리**: STT 한 번에 수 초~수십 초가 걸린다. 이걸 API 요청 안에서 처리하면 그동안 그 API 프로세스가 다른 사용자 요청을 못 받는다. 그래서 "API는 접수만 하고 큐에 넣고, 워커가 처리하고, 화면은 상태를 폴링"하는 구조를 쓴다.
- **LLM 게이트웨이를 하나로 모으는 이유**: GPU 6GB에는 모델을 1개만 올릴 수 있다. 여러 곳(면접, 코딩, 평가, 공고 생성)이 Ollama를 직접 부르면 서로 순서를 모른 채 경쟁한다. 게이트웨이 하나가 "지금 누구 차례인지"를 정해야 면접 중인 지원자가 배치 평가 때문에 기다리는 일을 막을 수 있다.
- **코드 실행기를 별도 호스트로 두는 이유**: 지원자가 제출한 코드는 신뢰할 수 없는 코드다. 같은 서버에 두면 탈출 시 DB 비밀번호까지 노출된다.

---

4. AI 처리 구조 (전부 온프레미스, D1)

4.1 GPU 6GB 예산 [추정]

항목	메모리	비고
LLM 7~8B Q4 양자화 또는 4B급 모델	약 2.5~5GB	모델 후보는 PoC로 결정 [미결정]
KV 캐시 (컨텍스트 4,096 토큰, 동시 1건)	약 0.5~1GB	`num_ctx=4096`
여유	약 0.5GB	
합계	**≈ 6GB**	**모델 2개 동시 상주 불가** → 모든 LLM 작업이 모델 1개를 공유

- **TR-AI-01 [확정]** Ollama 설정: `OLLAMA_MAX_LOADED_MODELS=1`, `OLLAMA_NUM_PARALLEL=1`, `keep_alive=-1` (모델 상주, 교체 로딩 지연 방지).
- **TR-AI-02 [확정]** 모델은 **1종**만 사용한다. 면접(한국어), 코딩 도우미, 평가, 공고 생성을 같은 모델로 처리하므로 **한국어 + 코드 둘 다 무난한 모델**을 PoC 기준으로 고른다. 모델을 바꿔 끼우면 매번 수 초~수십 초의 로딩 지연이 생기기 때문이다.
- **TR-AI-03 [확정]** STT·TTS·임베딩은 **CPU에서 실행**한다. GPU를 LLM 전용으로 남기기 위해서다.

4.2 작업별 예상 지연 [추정 — PoC 실측 필수]

작업	출력 길이	예상 지연(대기 없을 때)	사용자가 기다리는가
꼬리질문 판단·생성	~150 토큰	5~10초	**예 (면접 중)**
코딩 도우미 응답	300~500 토큰	첫 토큰 2~5초, 완료 10~20초 (스트리밍)	예 (스트리밍으로 체감 완화)
공고 초안 생성	~800 토큰	25~40초 (스트리밍)	예 (B4 2단계)
이력서 필드 추출	~400 토큰	10~20초	예 (A4, 폴링)
면접 문항별 선평가	~150 토큰	문항당 약 5초 (면접 진행 중 처리)	아니오 (비동기)
면접 종합 피드백 (강점3·개선점3)	~250 토큰	약 8~10초	아니오 (면접 종료 후)
STT (CPU, small int8)	—	녹음 길이의 약 0.3~0.5배	예 → 분할 전사로 완화 (7.3)

> **솔직한 한계 [확정]**: 이 구성에서 **동시에 원활하게 면접을 볼 수 있는 인원은 1~2명 수준**이다 [추정]. 개발·시연 환경으로는 충분하지만 실제 서비스 규모는 아니다. PRD 7.1대로 **실무 환경에서는 더 큰 GPU(또는 GPU 여러 대 + vLLM)로 확장**해야 하며, 이 TRD의 큐·게이트웨이 구조는 확장할 때 그대로 유지된다(게이트웨이 뒤의 서빙 엔진만 교체).

4.3 GPU 부담을 줄이는 설계 [확정]

ID	방법	효과
TR-AI-10	**기본 문항 10개는 면접 시작 전에 미리 준비**한다. 질문은행/관리자 입력은 SQL로 바로 고르고, RAG 기반 기업 질문은 **관리자가 공고를 설정할 때(B8)** 미리 생성해 질문은행에 넣는다	면접 중 실시간 LLM 호출이 **꼬리질문(최대 4회)으로만** 줄어든다
TR-AI-11	자소서 질문 2개는 **지원 접수 직후** 저우선순위 작업으로 생성한다. 면접 시작 시점까지 준비되지 않았으면 질문은행의 일반 자소서 질문으로 대체한다	면접 시작이 LLM 대기 때문에 막히지 않음
TR-AI-12	기본 문항 10개의 TTS 음성을 **A6(장치 점검) 진입 시 미리 합성**해 MinIO에 캐시한다	질문 사이 TTS 대기 제거
TR-AI-13	꼬리질문 생성에 **12초 타임아웃** [제안]. 넘기면 꼬리질문을 건너뛰고 다음 기본 질문으로 진행하고 `follow_up_skipped_reason=TIMEOUT` 을 기록한다	GPU가 밀려도 면접이 멈추지 않음 (CLAUDE.md 제한사항 원칙 1: 대체 방법)
TR-AI-14	코딩테스트 질문 정책 검사는 **규칙 기반**으로 한다(LLM 분류기 미사용)	반려 판정에 GPU를 쓰지 않음. 아키텍처 §7의 "정책 반려 시 실제 추론 토큰 0"과도 맞음
TR-AI-15	면접 평가는 **답변이 확정될 때마다 문항 단위로 미리** 처리한다(4.5). 지원자가 다음 답변을 말하는 동안 GPU가 놀고 있으므로 그 시간을 쓴다	면접 종료 후 평가 대기 시간 대폭 단축 (D6)

4.4 LLM 게이트웨이 우선순위 [확정]

우선순위	작업	호출자	타임아웃
P0	면접 꼬리질문	api (면접 세션)	12초 → 생략
P1	코딩 도우미 채팅	api (코딩 세션, SSE)	60초 → 실패 처리 + 시험 토큰 복원
P2	공고 초안 생성, 이력서 필드 추출	api (관리자/지원자 대화형)	90초 → 재시도 안내
P3	면접 문항별 선평가·종합 피드백, 자소서 질문 사전 생성, RAG 질문 생성	worker	300초 → Celery 재시도

- **TR-AI-20** 게이트웨이는 `asyncio.PriorityQueue` + 동시 실행 1개(세마포어)로 구현한다. 실행 중인 작업은 끊지 않고, **다음 차례**를 우선순위로 정한다.
- **TR-AI-21** 낮은 우선순위가 계속 밀리는 것(starvation)을 막기 위해, 대기 120초가 넘은 작업은 한 단계씩 우선순위를 올린다 [제안].
- **TR-AI-22** 모든 호출에 `request_id`, `purpose`, `model_version`, `prompt_version`, `prompt_eval_count`(입력 토큰), `eval_count`(출력 토큰), `queue_wait_ms`, `latency_ms`를 기록한다(Ollama 최종 응답 청크가 토큰 수를 돌려준다).
- **TR-AI-23 [확정, D5]** 동시 면접 세션 상한(개발 환경 기본 2) [제안값]. `IN_PROGRESS` 세션 수가 상한 이상이면 `POST /interviews/{id}/start`가 아래를 반환하고 세션은 `READY`로 남는다. 상한 검사와 상태 전이는 **한 트랜잭션 안에서** 처리한다(PostgreSQL advisory lock). 두 명이 동시에 눌러 상한을 넘는 일을 막기 위해서다. `json { "error": { "code": "INTERVIEW_CAPACITY_FULL", "message": "이미 많은 면접자들이 면접 중입니다. 추후 다시 요청해주세요.", "details": { "estimatedWaitSec": 480 } } }` `estimatedWaitSec`은 진행 중 세션들의 남은 문항 수 × 문항당 평균 소요시간 중 최솟값으로 계산한다. **MVP 화면에는 표시하지 않고**(화면정의서 v1.3 A6 예약 영역), 값의 정확도를 로그로 쌓아 후속 버전에서 표시 여부를 정한다.

4.5 평가 처리 시간 분석과 단축 (D6)

v1.0 초안의 "면접 종료 → `REPORT_READY` ≤ 30분" 목표가 너무 길다는 지적에 따라 원인을 분석했다.

30분이 나온 이유 — 실제 계산량 때문이 아니라 **줄 서는 시간** 때문이다. | 원인 | 설명 | 영향 | |---|---|---| | ① GPU 1대를 모두가 공유 | 면접 꼬리질문(P0)·코딩 채팅(P1)·공고 생성(P2)이 평가(P3)보다 먼저 처리된다. 다른 면접이나 코딩테스트가 진행 중이면 평가는 계속 뒤로 밀린다 | **가장 큼.** 바쁜 시간대에는 분 단위로 대기 | | ② 면접이 끝난 뒤에야 평가 시작 | 답변 최대 14개(기본 10 + 꼬리 4) × 답변당 약 10초 + 종합 피드백 = 2~4분이 종료 시점에 몰려서 시작된다 | 대기열이 비어 있어도 2~4분 | | ③ 문항마다 긴 프롬프트 반복 | 루브릭 설명·공고 정보가 매 호출마다 다시 들어가 입력 처리 시간이 늘어난다 | 문항당 수 초 | | ④ 여러 면접이 동시에 끝남 | 평가 작업이 쌓이면 N명 × 2~4분 | 2명이면 최대 8분 | | (영향 없음) STT | 분할 전사로 면접 중에 이미 끝나 있다(TR-IV-20) | — |

개선 설계 [확정] - **TR-EV-20 문항별 선평가**: 답변이 확정되면(`finalize`) 그 문항의 루브릭 평가를 바로 P3로 등록한다. 지원자가 다음 질문을 듣고 답하는 동안(문항당 1~2분) GPU는 대부분 놀고 있으므로 그 사이에 처리된다. 면접이 끝나면 **마지막 문항 평가 + 종합 피드백 1회만 남는다**. - **TR-EV-21 짧은 평가 출력**: 문항별 평가 출력은 점수 4개 + 근거 인용 1개 + 신뢰도로 제한한다(약 150 토큰, 약 5초). 이렇게 해야 선평가가 실행

중일 때 같은 GPU를 기다리는 꼬리질문(P0)이 최대 5초만 지연된다. - **TR-EV-22 프롬프트 고정부 재사용**: 루브릭·공고 정보로 된 고정 앞부분을 모든 문항 평가에 똑같이 두어 Ollama의 프롬프트 캐시가 재사용되게 한다(같은 세션에서 연속 호출 시 입력 처리 시간 감소) [추정 — PoC로 효과 확인]. - **TR-EV-23 꼬리질문 보호**: P0 요청이 대기 중이면 새 P3 작업은 시작하지 않는다(이미 실행 중인 것은 끝까지 수행).

개선 후 목표 [추정]: 면접 종료 → `REPORT_READY` **대기열이 비면 약 1~3분, 바쁠 때 약 10분 이내**(TR-PERF-06 갱신). 이보다 더 줄이려면 GPU 증설이 필요하다(현재 하드웨어의 한계).

리스크: 선평가가 GPU를 쓰는 동안 다른 지원자의 꼬리질문이 최대 약 5초 늦어질 수 있다 → 꼬리질문 타임아웃(12초) 안이라 생략까지 가는 경우는 드물 것으로 예상하나, PoC에서 꼬리질문 생략률을 측정해 확인한다.

4.6 STT / TTS / 임베딩

- **TR-AI-30 STT**: faster-whisper `small`(int8, CPU)를 기본으로 하고, 한국어 정확도가 부족하면 `medium`을 PoC로 비교한다 [미결정]. 전사 결과의 `avg_logprob`, `no_speech_prob`로 **전사 품질 불량**을 판정한다(기준값은 PoC로 정함). 불량이면 화면정의서 A7의 "다시 녹음해주세요"로 연결한다.
- **TR-AI-31 TTS**: 한국어를 지원하는 CPU 실행 가능 엔진을 PoC로 고른다(후보 MeloTTS-KR, Piper-KR) [미결정]. 꼬리질문처럼 실시간 합성이 필요한 문장은 1~2문장이라 CPU로도 수 초 안에 처리할 수 있다 [추정].
- **TR-AI-32 TTS 장애 대체**: 서버 TTS가 실패하면 질문 텍스트를 계속 보여주고 브라우저 내장 `speechSynthesis`로 읽는다. 이 사실을 `tts_fallback=true`로 기록한다(지원자 간 음성 품질 차이를 관리자가 알 수 있게).
- **TR-AI-33 임베딩**: CPU에서 sentence-transformers로 계산한다. 문서 임베딩은 업로드 시 배치로 처리되므로 CPU로 충분하다. 차원은 모델이 정해지면 `vector(N)`으로 고정한다(모델 변경 = 재임베딩 + 인덱스 버전 증가).

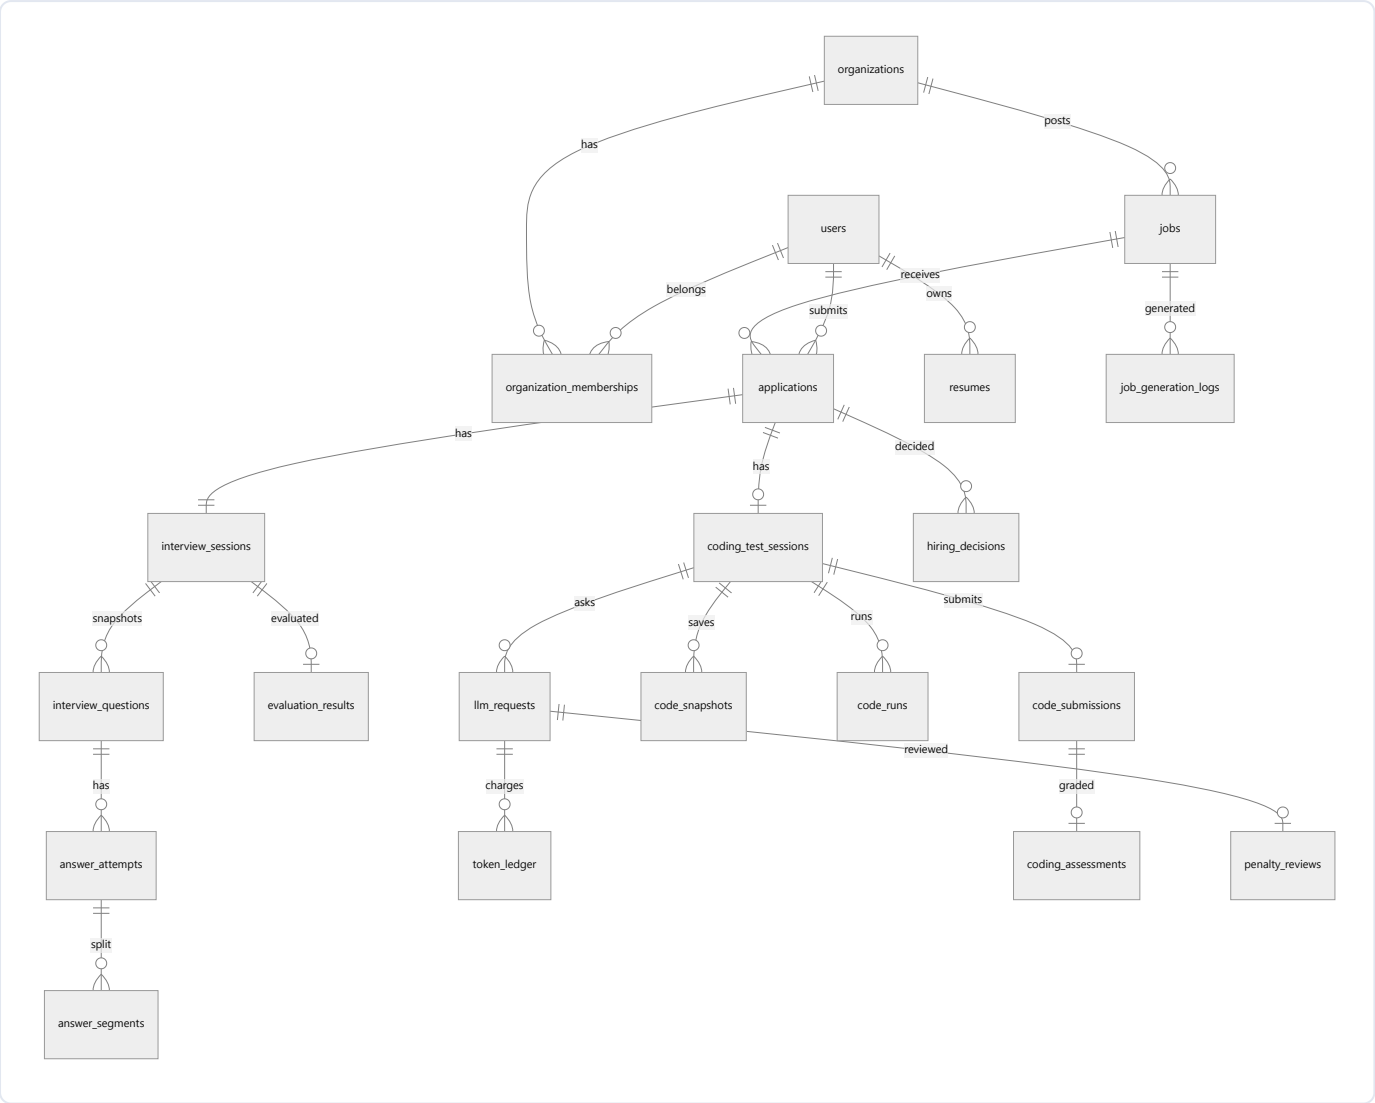
---

5. 데이터 설계

5.1 원칙 [확정]

- 모든 업무 테이블에 `organization_id`(지원자 개인 데이터는 `user_id`)를 둔다. 모든 조회 쿼리는 이 범위 조건을 **리포지토리 계층에서 강제**한다(화면에서 숨기는 것으로 대체 금지, PRD 7.2).
- 출제된 질문, 루브릭, 가중치, 문제, 시나리오, 정책은 **변경 불가 스냅샷(버전 행)**으로 참조한다. 수정하면 새 버전 행을 만든다.
- 토큰 원장, 평가 변경, 채용 결정, 감사 로그는 **append-only**로 둔다. 앱 DB 계정에서 `UPDATE/DELETE` 권한을 회수하고, 트리거로 한 번 더 막는다.
- 대용량 원본(PDF, 음성, 코드 스냅샷, 긴 LLM 응답)은 MinIO에 두고, DB에는 `*_ref`(객체 키)만 저장한다.
- 이름 규칙: **DB 테이블·컬럼은 snake_case**(SQL 관례, 아키텍처 v1.0과 동일), **Python/TypeScript 변수·함수는 camelCase**(CLAUDE.md), **API JSON 필드는 camelCase**. Pydantic `alias_generator`로 변환한다.

5.2 ERD (핵심)



5.3 주요 테이블 정의

계정/권한 | 테이블 | 핵심 컬럼 | 비고 | |---|---|---| | `users` | id, email(unique), password_hash(Argon2id), role(`APPLICANT` / `ADMIN`), name, phone, created_at | 관리자는 운영자가 스크립트로 발급 (PRD 4.1) | | `organizations` | id, name, created_at | | | `organization_memberships` | user_id, organization_id, role | 관리자 ↔조직 연결 | | `auth_sessions` | id(랜덤 256bit), user_id, expires_at, created_at, revoked_at | 서버 측 세션 (8.1) | | `consents` | id, user_id, application_id, consent_version, notice_text_hash, agreed_at | 화면정의서 A5: 어떤 문구에 동의했는지 추적 |

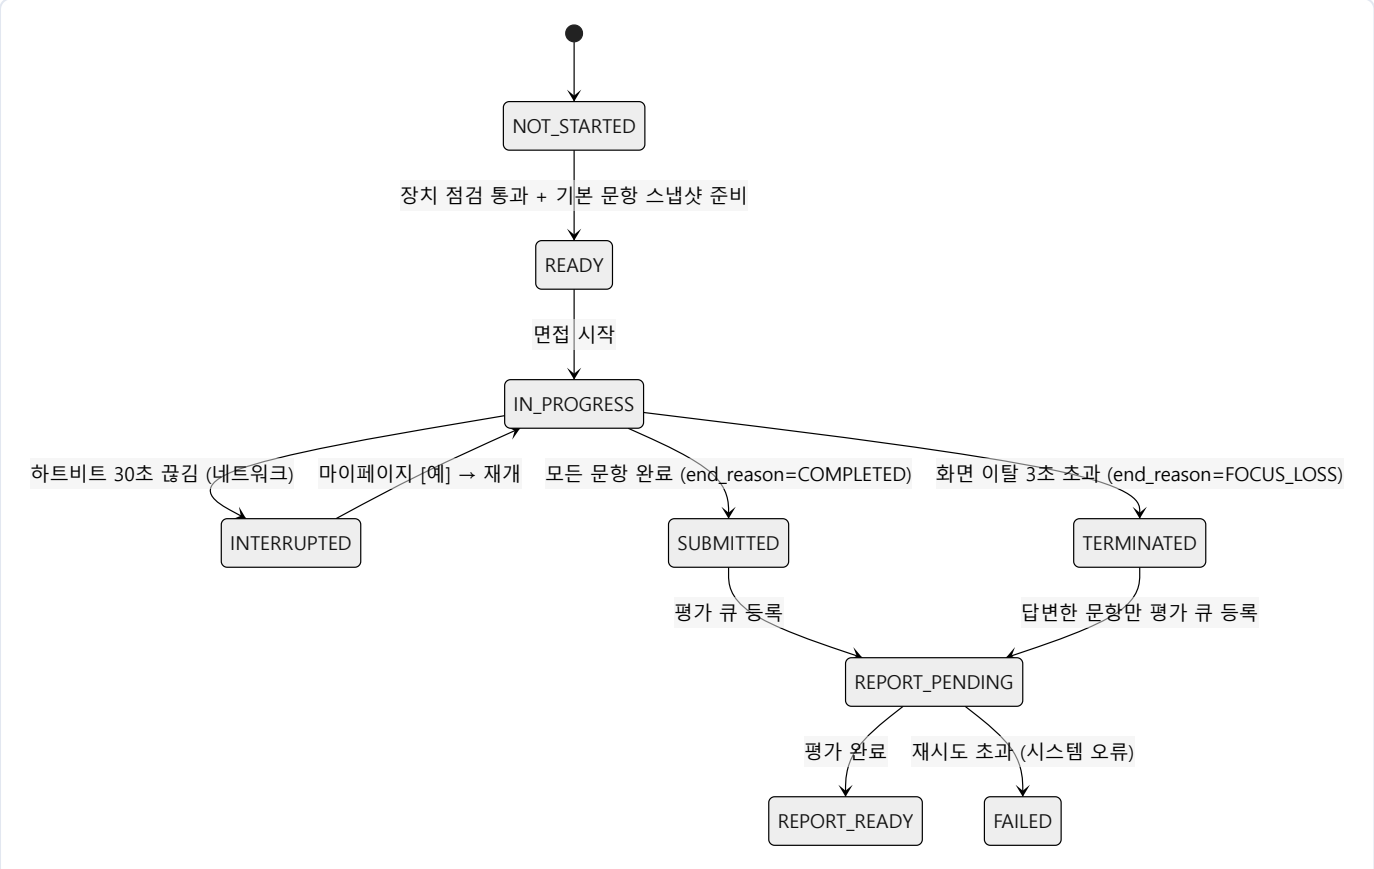
채용 | 테이블 | 핵심 컬럼 | 비고 | |---|---|---| | `jobs` | id, organization_id, title, description, requirements, preferred, conditions, status(`DRAFT` / `PUBLISHED` / `CLOSED`), deadline_at, **coding_test_enabled**(boolean, 기본 false), coding_problem_id(nullable), interview_template_id, rubric_version_id, created_by, published_at | D3에 따라 순서 컬럼 없음. 화면정의서 B3 체크박스 = `coding_test_enabled` | | `applications` | id, job_id, user_id, resume_id, status, submitted_at | **unique(job_id, user_id)** → 중복 지원 방지 (PRD 6.2) | | `application_events` | id, application_id, event_type, payload, created_at | 상태 변경 이력 (append-only) | | `resumes` | id, user_id, source(`PDF` / `MANUAL`), pdf_ref, extracted_json, confirmed_json, extract_status, version | 추출 결과와 확정 결과 분리 | | `hiring_decisions` | id, application_id, decision(`PASS` / `FAIL` / `HOLD`), reason,

decided_by, decided_at | append-only, 최신 행이 현재 결정 | | `job_generation_logs` | id, organization_id, job_id(nullable), inputs_json, draft_json, model_version, prompt_version, review_confirmed, published_without_review, sensitive_term_hits, created_at | PRD 10.2 생성 이력 |

`applications.status` 값 [확정]: `SUBMITTED` → `INTERVIEW_IN_PROGRESS` → `INTERVIEW_DONE` → (`coding_test_enabled` 이면) `CODING_IN_PROGRESS` → `CODING_DONE` → `UNDER_REVIEW` → `DECIDED`. 화면정의서 A11/B5의 뱃지는 이 값과 각 세션 상태를 조합해 표시한다.

면접 | 테이블 | 핵심 컬럼 | 비고 | |---|---|---| | `interview_templates` | id, organization_id, job_id, version, follow_up_limit(기본 4), time_limit_sec | B8 설정. 수정 시 새 버전 | | `template_question_slots` | template_id, category(`PERSONALITY` / `COVER_LETTER` / `COMPANY` / `JOB`), count, source(`MANUAL` / `BANK` / `RAG`) | 기본 2/2/2/4 | | `question_bank` | id, organization_id(nullable=공용), category, difficulty, text, is_active, times_used, source_document_id | 메타데이터는 관계형 (아키텍처 §6) | | `question_embeddings` | question_id, embedding vector(N), model_version | | | `interview_sessions` | id, application_id, template_version, rubric_version_id, model_version, prompt_version, **status**, **end_reason**, current_question_index, follow_up_count, last_heartbeat_at, started_at, ended_at | 아래 상태 머신 | | `interview_questions` | id, session_id, order_no, category, is_follow_up, parent_question_id, text, tts_audio_ref, source_ref, created_at | **출제 스냅샷** (변경 불가) | | `answer_attempts` | id, question_id, attempt_no, audio_ref, transcript, stt_avg_logprob, stt_no_speech_prob, quality_ok, duration_ms | 재녹음 시 attempt_no 증가 | | `answer_segments` | id, attempt_id, seq, audio_ref, transcript, status | 분할 전사 (7.3) |

면접 상태 머신 [확정: PRD 6.3 + D2]



- `TERMINATED` (D2)는 **지원자 행동으로 인한 종료**, `FAILED` 는 **시스템 오류**다. 둘을 섞지 않아야 통계(PRD 8장 "세션 중단율")와 재개 판단이 정확해진다.

- 평가가 끝나 `REPORT_READY`가 되어도 **`end_reason=FOCUS_LOSS`는 영구 보존**한다. 이 값으로 (1) 마이페이지 재개 모달 대상에서 제외하고(화면정의서 A11), (2) 코딩테스트 진입을 막고(A8), (3) 리포트에 "부분 평가" 표시를 한다.

평가 | 테이블 | 핵심 컬럼 | 비고 | |---|---|---| | `rubric_versions` | id, organization_id, job_id, version, created_at | | | `rubric_weights` | rubric_version_id, target(`INTERVIEW`/`CODING`), item, weight | 합계 100 (B9) | | `evaluation_results` | id, session_id, rubric_version_id, model_version, item_scores_json, total_score, strengths_json(3개), improvements_json(3개), evidence_json, confidence, needs_review, **is_partial**, answered_count, planned_count, created_at | **지원자 공개 필드 / 관리자 전용 필드가 한 행에 있으므로 응답 스키마로 분리 (8.3)** | | `answer_evaluations` | id, question_id, attempt_id, rubric_version_id, model_version, scores_json, evidence_quote, confidence, created_at | 문항별 선평가 결과 (TR-EV-20). unique(question_id) | | `evaluation_adjustments` | id, evaluation_id, field, before, after, reason, adjusted_by, created_at | 관리자 점수 조정 이력 (append-only) | | `admin_notes` | id, application_id, author_id, body, created_at | |

코딩테스트 (코딩테스트 v0.6 데이터 모델 계승) | 테이블 | 핵심 컬럼 | 비고 | |---|---|---| | `coding_problems` | id, organization_id, version, title, statement, constraints, language(`python`), time_limit_sec, memory_mb | | | `coding_test_cases` | id, problem_id, is_public, input_ref, expected_ref | **llm-gateway DB 계정은 이 테이블 SELECT 권한 없음** (7.4) | | `scenario_versions` | id, problem_id, scenario_type(`NORMAL`/`LIMITED_INFO`/`ERROR_INDUCING`/`AMBIGUOUS`), system_prompt_ref, fixed_responses_json, context_docs_ref, qa_passed_at | 함정 시나리오 (플로우 10) | | `coding_test_sessions` | id, application_id, problem_version, scenario_version, model_version, question_policy_version, penalty_policy_version, exam_token_budget, exam_token_balance, status, deadline_at, last_heartbeat_at, started_at, submitted_at | | | `llm_requests` | request_id(클라이언트 생성 UUID, PK), session_id, prompt, policy_version, disposition(`ALLOWED`/`CLARIFY`/`REJECTED`), rejection_code, responsibility(`APPLICANT`/`SYSTEM`/`UNDETERMINED`), created_at | 멱등 키 겸용 | | `llm_messages` | id, request_id, role, content_ref, response_status, model_version, scenario_version, latency_ms, tokens_estimated(boolean) | | | `token_ledger` | ledger_id, session_id, request_id, event_type(`RESERVE`/`CHARGE`/`REFUND`/`ADJUST`), exam_tokens_delta, actual_input_tokens, actual_output_tokens, balance_after, created_at | **append-only, unique(request_id, event_type)** → 중복 차감 방지 | | `penalty_reviews` | id, request_id, rubric_version_id, proposed_penalty, final_penalty, reviewer_id, review_reason, appeal_status | | | `editor_events` | id, session_id, event_type, diff_ref, source_tag(`TYPED`/`LLM_INSERT`/`PASTE`), created_at | 키 입력 단위 기록 금지 (v0.6) | | `code_snapshots` | id, session_id, code_ref, reason(`AUTO`/`RUN`/`SUBMIT`), created_at | | | `code_runs` | id, session_id, snapshot_id, kind(`PUBLIC`/`HIDDEN`), status, exit_code, error_type, **run_health**(`NORMAL`/`ABNORMAL`), stdout_ref, stderr_ref, runtime_ms, memory_kb, passed, created_at | 응시 중 실행 = D4 중간 체크. `passed`는 HIDDEN 실행에만 채움 | | `code_submissions` | id, session_id, final_snapshot_id, submitted_at, **final_result**(`CORRECT`/`INCORRECT`/`PENDING`), passed_count, total_count | D4 최종 체크 결과 (7.5). passed/total은 관리자 전용 | | `coding_assessments` | id, submission_id, rubric_version_id, auto_scores_json, final_scores_json, rationale, reviewer_id, confirmed_at | 자동 초안과 관리자 확정 분리 |

`coding_test_sessions.status` [확정]: `NOT_STARTED` → `IN_PROGRESS` ⇄ `INTERRUPTED` → `SUBMITTED` → `GRADING` → `GRADED` (`FAILED`는 시스템 오류).

운영 | 테이블 | 핵심 컬럼 | |---|---| | `notifications` | id, type, **channel(`EMAIL`/`IN_APP`)**, target_user_id, application_id, title, dedup_key(unique), scheduled_for, status, attempts, last_error, **read_at** (D6: 평가 완료는 `IN_APP`만) | | `schedules` | id, application_id, kind, starts_at, ends_at, status, accept_token_hash | |

`background_jobs` | id, job_type, ref_id, status, attempts, error_code, created_at, updated_at | | `audit_logs` | id, actor_id, action, target_type, target_id, ip, created_at (append-only) | | `idempotency_keys` | key, user_id, endpoint, response_status, response_body_hash, created_at (24시간 보관) | | `knowledge_documents` / `document_chunks` | 기업 공개 문서 / 청크 + embedding vector(N), index_version |

5.4 저장소 경로 규칙 (MinIO)

```
resumes/{userId}/{resumeId}.pdf
interviews/{sessionId}/q{orderNo}/attempt{n}/seg{seq}.wav
interviews/{sessionId}/tts/q{orderNo}.mp3
coding/{sessionId}/snapshots/{snapshotId}.py
coding/{sessionId}/llm/{requestId}.json
brand/…  (공개 버킷, 9.6)
```

- 공개 버킷은 `brand/` 만 둔다. 나머지는 전부 비공개이고 **만료 5분짜리 서명 URL**로만 접근한다.

---

6. API 요구사항

6.1 공통 규격 [확정]

- 기본 경로 `/api/v1`. JSON 필드는 camelCase.
- 인증: `HttpOnly; Secure; SameSite=Lax` 세션 쿠키. 상태를 바꾸는 요청(POST/PUT/PATCH/DELETE)은 `X-CSRF-Token` 헤더를 추가로 요구한다.
- 쓰기 요청 중 **중복 전송되면 안 되는 요청**(답변 제출, LLM 질문, 코드 제출, 채용 결정, 공고 게시)은 `Idempotency-Key` 헤더를 필수로 받는다. 같은 키로 다시 오면 처음 응답을 그대로 돌려준다.
- 오류 형식: `json { "error": { "code": "APPLICATION_DUPLICATED", "message": "이미 지원한 공고입니다.", "details": {} } }`
- 오래 걸리는 작업은 `202 Accepted` + `{ "jobId": "...", "status": "PENDING" }` 을 반환하고, 클라이언트는 상태 조회 API를 폴링하거나 SSE를 구독한다.
- 목록 API는 `?page=&size=` (size 최대 50) 페이지네이션.

6.2 엔드포인트 목록

권한: `PUB` 비로그인 허용, `APP` 지원자 본인, `ADM` 같은 조직 관리자.

인증 / 공고 / 지원 | 메서드 | 경로 | 권한 | 설명 | 화면 | |---|---|---|---|---| | POST | `/auth/signup` | PUB | 지원자 회원가입 | A3 | | POST | `/auth/login` | PUB | 로그인. 응답에 `role`, 검증된 `redirectTo` 포함 | A3 | | POST | `/auth/logout` | APP/ADM | 세션 폐기 | GNB | | GET | `/auth/me` | APP/ADM | 현재 사용자·역할 | GNB 분기 | | GET | `/jobs` | PUB | 공개 공고 목록 (`?category=&q=&page=`) | A1 | | GET | `/jobs/{jobId}` | PUB | 공고 상세 (로그인 시 `alreadyApplied` 포함) | A2 | | POST | `/jobs/{jobId}/applications` | APP | 지원 접수 (중복 시 409) | A5→A6 | | GET | `/me/applications` | APP | 내 지원 현황 + 재개 가능 세션 목록 | A11 | | GET | `/me/applications/{applicationId}/evaluation-summary` | APP | **지원자용 평가 요약** (8.3) | A11 | | POST | `/consents` | APP | 동의 기록 (버전·문구 해시) | A5 | | GET | `/me/notifications?unreadOnly=` | APP | 사이트 내

알림 목록 + 읽지 않은 개수 (D6) | C1 | | POST | `/me/notifications/{notificationId}/read` | APP | 읽음 처리 | C1 | | POST | `/me/notifications/read-all` | APP | 모두 읽음 | C1 |

이력서 / 문서 | 메서드 | 경로 | 권한 | 설명 | 화면 | |---|---|---|---|---| | POST | `/documents/upload-url` | APP | PDF 업로드용 서명 URL 발급 (≤10MB, `application/pdf`) | A4 | | POST | `/documents/{documentId}/confirm` | APP | 업로드 완료 → 추출 작업 등록 (202) | A4 | | GET | `/resumes/me` | APP | 내 이력서 + 추출 상태 | A4 | | PUT | `/resumes/me` | APP | 이력서 확정/수정 (새 버전) | A4 |

면접 | 메서드 | 경로 | 권한 | 설명 | 화면 | |---|---|---|---|---| | POST | `/interviews/{sessionId}/prepare` | APP | 기본 문항 스냅샷 확정 + TTS 사전 합성 등록 | A6 진입 | | POST | `/interviews/{sessionId}/start` | APP | `READY→IN_PROGRESS` (정원 초과 시 409) | A6→A7 | | GET | `/interviews/{sessionId}/current` | APP | 현재 질문, TTS URL, 진행률(`3/10`, 꼬리질문이면 `isFollowUp=true`로 같은 번호 유지, D10) | A7 | | POST | `/interviews/{sessionId}/answers/{questionId}/segments` | APP | 답변 분할 음성 업로드 (7.3) | A7 | | POST | `/interviews/{sessionId}/answers/{questionId}/finalize` | APP | 답변 확정 → 품질 판정·꼬리질문 판단 (202) | A7 | | POST | `/interviews/{sessionId}/heartbeat` | APP | 10초 간격 하트비트 | A7 | | POST | `/interviews/{sessionId}/focus-events` | APP | `HIDDEN` / `VISIBLE` 이벤트 (`sendBeacon`) | A7 | | POST | `/interviews/{sessionId}/terminate` | APP | 화면 이탈 강제 종료 (`reason=FOCUS_LOSS`) | A7→A8 | | POST | `/interviews/{sessionId}/resume` | APP | `INTERRUPTED→IN_PROGRESS` | A11 모달 [예] | | GET | `/interviews/{sessionId}/status` | APP | 상태 + `endReason` + `codingTestAvailable` | A8 |

코딩테스트 | 메서드 | 경로 | 권한 | 설명 | 화면 | |---|---|---|---|---| | POST | `/coding/sessions/{sessionId}/start` | APP | 버전 고정, 마감시각 확정 | A9 | | GET | `/coding/sessions/{sessionId}` | APP | 문제, 남은 시간(서버 기준), 마지막 스냅샷 | A9 | | POST | `/coding/sessions/{sessionId}/snapshots` | APP | 자동 저장 | A9 | | POST | `/coding/sessions/{sessionId}/llm-requests` | APP | LLM 질문 (SSE 스트리밍 응답, `request_id` 필수) | A9 | | GET | `/coding/sessions/{sessionId}/token-balance` | APP | 남은 시험 토큰 | A9 | | POST | `/coding/sessions/{sessionId}/runs` | APP | 공개 예제 입력으로 실행 = 중간 체크 (202) | A9 | | GET | `/coding/runs/{runId}` | APP | 실행 결과: `runHealth`, `errorType`, `stdout`, `stderr` (정답 일치 필드 없음) | A9 | | POST | `/coding/sessions/{sessionId}/submit` | APP | 최종 제출 (스냅샷 고정) | A9→A10 | | GET | `/coding/sessions/{sessionId}/events` | ADM | 이벤트 타임라인 | B6 |

관리자 | 메서드 | 경로 | 권한 | 설명 | 화면 | |---|---|---|---|---| | GET | `/admin/dashboard/summary` | ADM | 요약 카드 집계 | B1 | | GET / POST | `/admin/jobs` | ADM | 공고 목록 / 생성 | B2, B3 | | GET / PUT | `/admin/jobs/{jobId}` | ADM | 공고 조회 / 수정 | B3 | | POST | `/admin/jobs/{jobId}/publish` | ADM | 게시 (`reviewConfirmed`, `forcePublish` 포함) | B3, B4 | | POST | `/admin/jobs/{jobId}/close` | ADM | 마감 | B2 | | POST | `/admin/job-drafts/generate` | ADM | **공고 자동 생성** (SSE 스트리밍, 완료 시 `sensitiveTerms` 포함) | B4 | | POST | `/admin/job-drafts/check-terms` | ADM | 편집된 초안의 차별 표현 재검사 | B4 | | GET | `/admin/applications?jobId=&stage=` | ADM | 지원자 목록 | B5 | | GET | `/admin/applications/{applicationId}` | ADM | 지원자 상세 (이력서·답변·코딩 결과) | B6 | | GET | `/admin/evaluations/{applicationId}` | ADM | **관리자용 평가 전체** (8.3) | B6 | | POST | `/admin/evaluations/{evaluationId}/adjustments` | ADM | 점수 조정 (사유 필수) | B6 | | POST | `/admin/penalty-reviews/{reviewId}` | ADM | 감점 후보 확정/조정 | B6 | | POST | `/admin/applications/{applicationId}/notes` | ADM | 관리자 메모 | B6 | | POST | `/admin/applications/{applicationId}/decisions` | ADM | 최종 결정 + 통지 (202) | B7 | | GET / PUT | `/admin/jobs/{jobId}/interview-template` | ADM | 질문 설정 (새 버전 저장) | B8 | | GET | `/admin/question-

`bank?category=&q=` | ADM | 질문은행 검색 | B8 | | GET / PUT | `/admin/jobs/{jobId}/rubric-weights` | ADM | 가중치 (합계 100 검증) | B9 | | GET / POST / PUT | `/admin/schedules` | ADM | 일정 | B10 | | GET | `/admin/notifications` | ADM | 발송 이력 | B10 | | GET | `/admin/stats?category=&from=&to=` | ADM | 직무별 통계 | B11 | | GET | `/admin/stats/export.csv` | ADM | CSV 내보내기 | B11 | | POST | `/admin/knowledge-documents` | ADM | 기업 공개 문서 업로드 → RAG 색인 | B8 |

공개 링크 | 메서드 | 경로 | 권한 | 설명 | |---|---|---|---| | GET | `/schedules/respond?token=` | PUB(서명 토큰) | 일정 수락/조율 (만료 72시간 [제안]) |

---

7. 기능별 기술 요구사항

7.1 로그인 및 복귀 경로 (PRD 6.1, 화면정의서 A3, Mermaid 01B)

- **TR-AUTH-01** 비밀번호는 Argon2id로 해시한다. 로그인 실패 5회/10분이면 해당 계정·IP를 10분간 제한한다 [제안].
- **TR-AUTH-02** `returnTo`는 아래 **화이트리스트 정규식**만 허용한다. 맞지 않거나 역할과 맞지 않으면(예: 지원자가 `/admin`) `/jobs`(A1)로 대체한다. `text ^/jobs$ ^/jobs/\d+$ ^/jobs/\d+/apply$ ^/me(/[a-z-]+)?$` 관리자는 `returnTo`와 관계없이 `/admin`(B1)으로 보낸다.
- **TR-AUTH-03** 서버가 로그인 응답에 최종 `redirectTo`를 계산해서 내려준다. 클라이언트가 직접 판단하지 않는다.
- **TR-AUTH-04** 관리자 계정이 지원자 전용 API를 부르면 `403 APPLICANT_ROLE_REQUIRED`를 반환한다(화면정의서 A2 "지원자 권한 필요").
- **TR-AUTH-05** 관리자 발급은 운영자용 CLI(`python -m app.cli createAdmin --org ... --email ...`)로 한다. 웹에 관리자 가입 화면을 두지 않는다.

7.2 공고·지원·이력서 (PRD 6.2, 화면정의서 A1/A2/A4/A5)

- **TR-JOB-01** 공고 목록은 Next.js 서버 렌더링(SSR)으로 그린다(검색 노출).
- **TR-JOB-02** 중복 지원은 DB unique 제약으로 막고, 위반 시 `409 APPLICATION_DUPLICATED`를 반환한다(화면 확인만 믿지 않음).
- **TR-RES-01** PDF는 서명 URL로 MinIO에 직접 올린다(API 서버 경유 안 함). 확인 단계에서 크기(≤10MB)와 파일 앞부분(`%PDF-`)을 검사한다.
- **TR-RES-02** 추출 순서: `pypdf` 텍스트 추출 → 추출 글자 수가 기준 미만이면 **스캔본으로 판단** → MVP에서는 OCR 대신 "텍스트를 읽을 수 없는 PDF입니다. 직접 작성해주세요" 안내 [제안]. (OCR은 CPU 부담이 크고 한국어 정확도 검증이 필요해서 후속으로 미룸. 아키텍처 §6의 "스캔일 때만 OCR"은 후속 버전에서 Tesseract(kor)로 검토)
- **TR-RES-03** 텍스트 → 학력/경력/스킬/자기소개 필드 추출은 LLM(P2)에 **JSON 스키마 강제 출력**(Ollama `format` 파라미터)으로 요청한다. 90초 안에 끝나지 않으면 필드를 비운 채 직접 입력하게 한다.
- **TR-RES-04** 동의 기록 시 고지 문구 전체의 SHA-256 해시와 `consent_version`을 함께 저장한다(화면정의서 A5).

7.3 AI 모의면접 (PRD 6.3, 화면정의서 A6/A7/A8, Mermaid 04/05)

① **질문 준비** - **TR-IV-01** `prepare` 시점에 템플릿 슬롯(기본 2/2/2/4)을 채워 `interview_questions`에 스냅샷으로 저장한다. 채우는 순서: 관리자 직접 입력 → 질문은행(SQL: 분야·난이도·활성, 같은 지원자 중복 제외, 출제 횟수 적은 순) → 사전 생성된 RAG 질문 → (모자라면) 공용 질문은행. - **TR-IV-02** 스냅샷과 함께 `template_version`, `rubric_version_id`, `model_version`, `prompt_version`을 세션에 고정한다. 이후 관리자가 B8/B9를 바꿔도 진행 중인 세션에는 영향이 없다.

② **질문 제시 → 녹음 (브라우저)** - **TR-IV-10** `getUserMedia({ audio: { echoCancellation: true, noiseSuppression: true }, video: true })`. 스트림은 A6에서 얻은 것을 A7까지 **재사용**한다(권한 팝업 재발생 방지). HTTPS 필수. - **TR-IV-11** 브라우저 자동재생 정책 때문에, A6의 "면접 시작하기" 클릭 시점에 `AudioContext`를 활성화한다. 이후 TTS 재생 → `ended` 이벤트 → 3-2-1 카운트 → 녹음 시작. - **TR-IV-12 영상은 저장·업로드하지 않는다** [제안]. 카메라는 화면 미리보기(A6, A7 PIP) 용도로만 쓴다. PRD 7.4가 시선/감정 분석을 금지하고, 화면정의서 B6에도 음성 재생만 있으므로 영상을 저장할 이유가 없다(저장 용량·개인정보 부담 제거).

③ **분할 전사 — CPU STT 지연을 줄이는 핵심 기법** - 문제: 60초 답변을 CPU로 한 번에 전사하면 20~30초가 걸린다 [추정]. 지원자가 그만큼 기다린다. - 해결: **말하는 동안 미리 전사**한다. - **TR-IV-20** 브라우저는 `AudioWorklet`으로 16kHz mono PCM을 받아 **약 10초 단위 WAV 조각**으로 잘라 업로드한다(`segments` API). (MediaRecorder의 webm 조각은 두 번째 조각부터 헤더가 없어 단독 디코딩이 안 되므로 쓰지 않는다) - **TR-IV-21** 조각마다 STT 작업을 큐에 넣는다. 지원자가 제출하면 **마지막 조각 하나만 남아 있으므로** 제출 후 대기 시간이 수 초로 줄어든다 [추정]. - **TR-IV-22** 조각 업로드가 실패하면 브라우저 메모리에 보관했다가 재시도한다. 같은 `seq`가 다시 오면 덮어쓰지 않고 멱등 처리한다.

④ **품질 판정 → 꼬리질문** - **TR-IV-30** 전체 전사가 비었거나 `no_speech_prob` / `avg_logprob`가 기준을 벗어나면 `quality_ok=false` → A7 "다시 녹음해주세요". 재녹음은 문항당 최대 2회 [제안], 그 뒤에는 현재 전사로 진행하고 `needs_review` 표시. - **TR-IV-31** 품질이 괜찮으면 LangGraph가 꼬리질문 여부를 판단한다. 조건: `follow_up_count < follow_up_limit(기본 4)` **그리고** LLM이 "논리적 모순/모호/이력서 불일치"를 근거와 함께 반환. 근거 없는 꼬리질문은 버린다. - **TR-IV-32** 꼬리질문은 P0, 12초 타임아웃(TR-AI-13). 생성되면 TTS(실시간 합성) 후 같은 레이아웃으로 제시한다. - **TR-IV-33 LangGraph 상태**: `{sessionId, questionQueue, currentQuestion, transcript, followUpCount, followUpLimit, resumeSummary, history}`. 노드: `presentQuestion → awaitAnswer → checkQuality → (retry | analyzeAnswer) → (generateFollowUp | nextQuestion | finish)`. 상태는 **매 노드 종료 시 PostgreSQL에 체크포인트**로 저장해 재개에 쓴다.

⑤ **네트워크 중단과 재개 (PRD 7.3)** - **TR-IV-40** 클라이언트는 10초마다 하트비트를 보낸다. Beat 작업이 30초마다 확인해 `IN_PROGRESS`인데 마지막 하트비트가 30초 넘은 세션을 `INTERRUPTED`로 바꾼다. - **TR-IV-41** 재개하면 **답변 도중 끊긴 문항은 처음부터 다시 출제**한다(부분 녹음은 폐기, `attempt_no` 증가). 이미 확정된 답변은 유지한다. - **TR-IV-42** `INTERRUPTED` 세션의 재개 가능 기한은 [미결정]. 기본값으로 **공고 마감 시각까지** 재개를 허용한다 [제안].

⑥ **화면 이탈 강제 종료 (D2, 화면정의서 A7/A8)** - **TR-IV-50** `visibilitychange`(hidden) 또는 `window blur` 시 3초 타이머를 시작한다. 3초 안에 돌아오면 취소한다. - **TR-IV-51** 숨김 상태가 되는 즉시 `navigator.sendBeacon('/focus-events', {type:'HIDDEN', at})`을 보낸다. 3초를 넘기면 `terminate`를 호출한다. - **TR-IV-52 탭 닫기 우회 방지**: 지원자가 3초 안에 탭을 닫으면 `terminate`가 호출되지 않고, 하트비트만 끊겨 `INTERRUPTED`(재개 가능)가 되는 구멍이 생긴다. 그래서 서버는 **`HIDDEN` 이벤트 이후 `VISIBLE` 없이 하트비트**

가 끊긴 세션은 `INTERRUPTED`가 아닌 `TERMINATED(FOCUS_LOSS)`로 분류한다. 네트워크 단절은 `HIDDEN` 이벤트가 앞서지 않으므로 구분할 수 있다. - **TR-IV-53 한계 명시 [확정]**: 포커스 감지는 브라우저 기능이라 **기술적으로 완전히 막을 수는 없다**(개발자 도구로 스크립트를 조작하거나 보조 기기를 쓰는 경우). 부정행위를 "확정"하는 장치가 아니라 **억제 장치**로 취급하고, 관리자 화면에 이탈 이벤트 타임라인을 보여주는 데 그친다(PRD 7.4의 "단정하지 않는다" 원칙과 일치). - **TR-IV-54** 화면정의서 A7 리스크(알림 확인 같은 짧은 이탈 오탐)를 측정하기 위해 모든 `HIDDEN/VISIBLE` 쌍의 지속시간을 기록한다. 3초 임계값은 이 데이터로 조정한다.

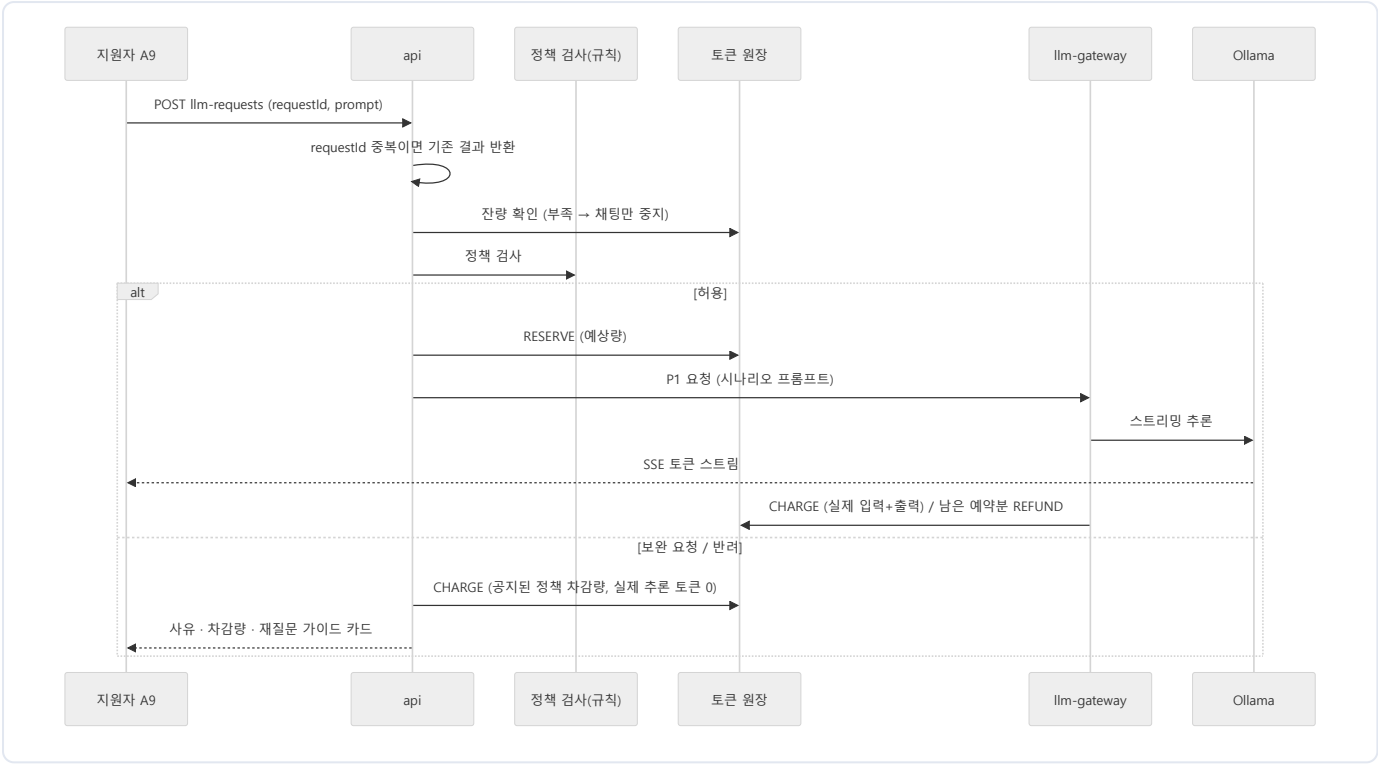
⑦ **부분 평가 (D2)** - **TR-IV-60** `TERMINATED` 세션은 **확정된 답변이 있는 문항만** 평가한다. `is_partial=true`, `answered_count`, `planned_count`를 저장한다. 두 값 모두 **기본 문항 기준**이다(`planned_count`=템플릿 기본 문항 수, 기본 10, D10). - **TR-IV-61** 총점 계산 시 **답하지 않은 기본 문항은 0점**으로 넣는다 [제안]. 답변한 문항만 평균 내면 "2문항만 잘 답하고 나간 지원자"가 높은 점수를 받는 문제가 생기기 때문이다. 관리자 화면에는 "답변 문항 기준 평균"도 함께 보여준다. - **TR-IV-62** 지원자 공개는 PRD 6.5 규칙 그대로(점수 + 강점/개선점) 적용하고, "강제 종료로 10문항 중 N문항만 평가되었습니다" 문구를 함께 표시한다. - **TR-IV-63 문항 단위 = 기본 문항 (D10)**: 꼬리질문(`is_follow_up=true`)은 `parent_question_id`가 가리키는 기본 문항에 속한다. 답변별 선평가(TR-EV-20)는 그대로 하고, 문항 점수는 기본 답변과 꼬리 답변의 루브릭 4항목을 각각 평균 내 1개로 만든다 [확정, 2026-10-26]. 기본 답변을 확정했으면 그 문항은 "답변함"으로 세고, 꼬리질문에 답하기 전에 강제 종료되면 기본 답변만으로 평가한다(꼬리 미응답은 감점하지 않음) [확정, 2026-10-26]. 총점 = 기본 문항 점수의 평균(미응답 0점).

7.4 코딩테스트 (PRD 6.4, 화면정의서 A9/A10, 코딩테스트 v0.6 플로우 09~13)

① **진입 조건** - **TR-CT-01** 서버가 아래를 모두 확인한다: `jobs.coding_test_enabled=true`, 면접 상태가 `SUBMITTED` 이상이며 `end_reason=COMPLETED`(D2: 강제 종료면 진입 불가), 코딩 세션이 `NOT_STARTED/IN_PROGRESS/INTERRUPTED`. - **TR-CT-02** 시작 시 `problem_version`, `scenario_version`, `model_version`, `question_policy_version`, `penalty_policy_version`, `exam_token_budget`을 세션에 고정한다. 시험 중 정책을 소급 변경하지 않는다(v0.6).

② **타이머와 자동 저장** - **TR-CT-10** 남은 시간은 **서버의 `deadline_at` 기준**이다. 클라이언트 타이머는 표시용이다. - **TR-CT-11** 마감 시각이 지나면 Beat 작업이 마지막 스냅샷으로 **자동 제출**한다. - **TR-CT-12** 네트워크 중단 중에도 마감 시각은 계속 흐른다 [제안]. (멈추게 하면 일부러 연결을 끊어 시간을 버는 악용이 가능하다. 장애로 인한 손해는 관리자가 시간 연장으로 보정) → [미결정]으로 12장에 등록. - **TR-CT-13** 편집 이벤트는 2초 디바운스로 diff를 저장하고, 30초마다 또는 실행/제출 시 전체 스냅샷을 저장한다. LLM 응답의 "에디터에 삽입"은 `source_tag=LLM_INSERT`로 구분한다. 키 입력 하나하나는 기록하지 않는다(v0.6).

③ **LLM 질문 처리 (플로우 13)**



- **TR-CT-20 정책 검사(규칙 기반, TR-AI-14)**: 코드·오류 정보 없이 짧은 지시("이거 고쳐줘") → `CLARIFY`; 직전 N개 질문과 거의 같은 무관 질문 반복(정규화 후 유사도) → `REJECTED`; "정답 코드 전부" 요청 → `question_policy_version`의 설정에 따라 허용/제한(요청만으로 감점 금지, v0.6); 그 외 → `ALLOWED`. 규칙 목록은 정책 버전 파일로 관리한다.
- **TR-CT-21 토큰 원장**: 잔액 변경은 세션 행을 `SELECT … FOR UPDATE`로 잠근 뒤 원장 행 추가 + `exam_token_balance` 갱신을 **한 트랜잭션**에서 한다. `unique(request_id, event_type)`로 재시도 시 중복 차감을 막는다.
- **TR-CT-22 스트리밍 취소**: 지원자가 응답 도중 취소하거나 연결이 끊기면 Ollama 최종 토큰 수가 오지 않는다. 이때는 받은 텍스트를 토크나이저로 세어 `tokens_estimated=true`로 기록하고 그만큼만 차감한다.
- **TR-CT-23 오탐/장애 복원**: 시스템 오류, 게이트웨이 타임아웃, 관리자가 오탐으로 판정한 반려는 `REFUND` 이벤트를 **추가**해 복원한다(원래 행은 지우지 않음). 해당 반려는 감점 집계에서 제외한다.
- **TR-CT-24** 잔량이 0이면 채팅 입력만 막고 편집·실행·제출은 허용한다(PRD 6.4).
- **TR-CT-25 반려 차감량**: 구체 수치는 미결정. 코드에서는 정책 버전 설정값(`rejectFixedFee`, `rejectChargeInputTokens`)으로만 읽고 하드코딩하지 않는다.

④ **함정 시나리오와 정답 유출 방지 (플로우 10)** - **TR-CT-30** 시나리오는 `scenario_versions`의 시스템 프롬프트·고정 응답·통제된 컨텍스트 문서로만 구성한다. 모델이 매번 같은 오류를 내도록 강제하기는 어려우므로, **재현성이 필요한 함정은 고정 응답(`fixed_responses_json`)으로 구현**한다(v0.6). - **TR-CT-31 [확정, 구조로 강제]** `llm-gateway`가 쓰는 DB 계정에는 `coding_test_cases`, `coding_assessments`, 정답 관련 테이블의 **SELECT 권한을 주지 않는다**. "프롬프트에 넣지 않도록 조심한다"가 아니라 **애초에 읽을 수 없게** 만든다. - **TR-CT-32** `qa_passed_at`이 비어 있는 시나리오는 세션에 할당할 수 없다.

⑤ **코드 실행기** - **TR-CT-40** 실행 1회 = 일회용 컨테이너 1개: `text docker run --rm --network none --memory 256m --memory-swap 256m --cpus 0.5 --pids-limit 64 --read-only --tmpfs /tmp:size=16m,noexec --user 65534:65534 --cap-drop ALL --security-opt no-new-privileges python:3.12-slim` (운영 환경: `--runtime runsc`) 테스트 케이스 1개당 시간 제한 5초 [제안], 전체 30초. - **TR-CT-41** 실행기 워커는 별도 호스트에서

`code_runs` 큐만 구독한다. 동시 실행 수 2 [제안]. API 컨테이너에 Docker 소켓을 마운트하지 않는다. - **TR-CT-42 [D4 반영]** 응시 중 "실행"은 문제에 공개된 예제 입력으로 코드를 돌리고 **실행 오류 여부(`runHealth`)와 프로그램 출력·오류 메시지만** 돌려준다. 기대 출력과의 비교·일치 여부는 응답에 넣지 않는다(정답 판정은 제출 후 최종 체크에서만). 비공개 테스트는 제출 후에만 실행하며 입력·기대값을 클라이언트에 보내지 않는다.

7.5 평가 및 리포트 (PRD 6.5, Mermaid 06, 플로우 11)

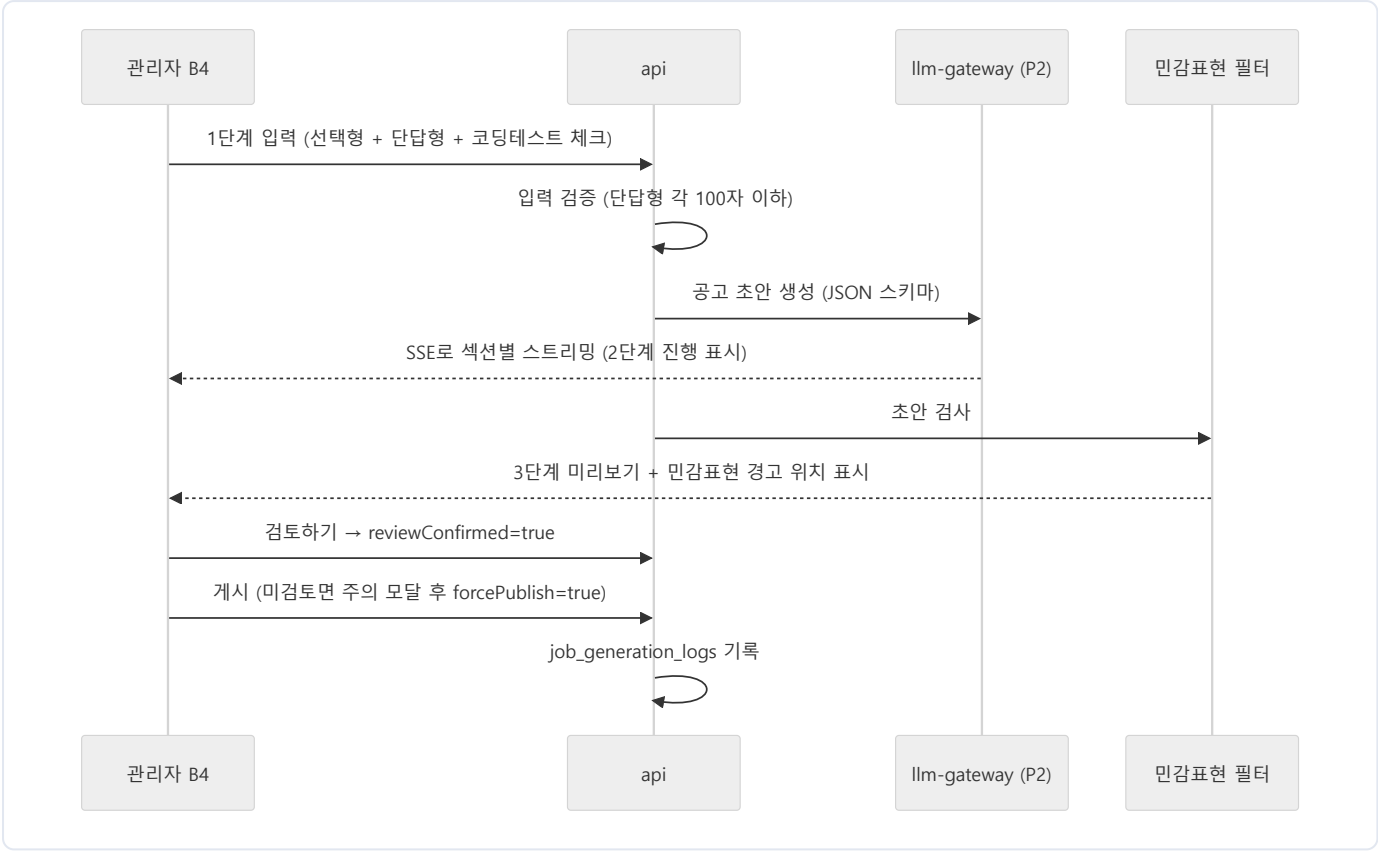
면접 평가 - **TR-EV-01** 답변 확정 시마다 평가 워커(P3)가 그 문항을 루브릭(논리성/전달력/전문성/내용 관련성)으로 미리 채점해 `answer_evaluations`에 저장한다(TR-EV-20). 출력은 JSON 스키마 강제: `{scores:{...}, evidenceQuote, confidence}`. - **TR-EV-02** 면접 종료(`SUBMITTED`/`TERMINATED`) → `REPORT_PENDING` → 아직 평가되지 않은 문항만 채점 → 공고별 고정 가중치로 합산 → 강점 3개·개선점 3개를 생성(Mermaid 06) → `REPORT_READY` → 사이트 내 알림 생성(TR-NOTI-06). - **TR-EV-03** `evidenceQuote`가 실제 전사문에 존재하는지 문자열 대조로 검증한다. 없으면 `needs_review=true`(LLM이 근거를 지어내는 것 방지). - **TR-EV-04** 실패 시 Celery 재시도 3회(지수 백오프). 그래도 실패하면 `FAILED` + 관리자 대시보드 "평가 대기" 카드에 표시. 작업은 `session_id` 기준 멱등이다(두 번 돌아도 결과 1개).

코딩테스트 평가 - **TR-EV-10 2단계 판정(D4)** | 단계 | 시점 | 판정 기준 | 지원자에게 보이는 문구 | |---|---|---|---| | 중간 체크 | 응시 중 "실행" | 종료코드 0, 예외 없음, 시간·메모리 제한 이내면 `NORMAL`, 아니면 `ABNORMAL`. **출력의 정답 여부는 보지 않음** | "정상 작동" / "비정상 작동" + 출력·오류 메시지 | | 최종 체크 | 제출 후 비동기 채점 | **모든 테스트(공개+비공개)의 출력이 기대값과 일치**하면 `CORRECT`, 하나라도 다르거나 실행 오류가 나면 `INCORRECT` | "테스트 정답을 맞히셨습니다" / "테스트 정답을 맞히지 못했습니다" | - 예(중간 체크): `IndexError`·무한루프(시간 초과) → 비정상 작동 / 오답을 출력하지만 오류 없이 끝남 → 정상 작동 - 출력 비교는 줄 끝 공백과 마지막 개행을 무시하고 비교한다(문제별 특수 비교 규칙은 문제 정의에 둔다) [제안]. - 통과 개수(`passed_count/total_count`)는 지원자에게 공개하지 않는다. 관리자 전용 정확성 점수(40점)는 통과율로 계산한다. - 최종 체크가 끝나면 사이트 내 알림을 생성한다(TR-NOTI-06). - **TR-EV-11** 자동 점수 초안: 정확성 40(비공개 테스트 통과율) / 코드 품질 20 / 검증·디버깅 20 / 프롬프트·AI 활용 판단 15 / 설명·근거 5. 정확성은 기계적으로 계산하고, 나머지는 LLM 초안 + 관리자 확정이다. - **TR-EV-12 반려 감점 후보**: 귀책(`APPLICANT`) 반려 횟수로 계산한 값을 **AI 활용 판단 15점 안에서** 감점 후보로 제시한다. 관리자 확정 전에는 최종 점수에 반영하지 않는다. `python def penaltyForRejections(count: int) -> float: table = [0.0, 0.0, 0.5, 1.5, 2.5] # 0회, 1회, 2회, 3회, 4회 (누적) return table[count] if count < len(table) else 3.0` - **TR-EV-13** AI 사용 횟수나 토큰 사용량만으로는 감점하지 않는다(v0.6). 이 규칙은 테스트로 보증한다(11장).

7.6 관리자 기능 (PRD 6.6, 화면정의서 B1~B11)

- **TR-ADM-01** 모든 `/admin/*` API는 의존성 주입(`Depends(requireAdmin)`)으로 역할을 확인하고, 리포지토리가 `organization_id = currentUser.organizationId` 조건을 **자동으로 붙인다**. 다른 조직 ID로 접근하면 존재 여부도 숨기도록 `404`를 반환한다.
- **TR-ADM-02** B3 코딩테스트 체크박스를 켰는데 `coding_problem_id`가 비어 있으면 게시를 거부한다(`422 CODING_PROBLEM_REQUIRED`).
- **TR-ADM-03** B8/B9 저장은 기존 행을 고치지 않고 **새 버전 행**을 만든다. B9는 서버에서도 합계 100을 검증한다.
- **TR-ADM-04** B7 결정은 `hiring_decisions`에 append하고, 통지 메일은 Celery로 비동기 발송한다. 결정 API가 메일 발송 성공을 기다리지 않는다.
- **TR-ADM-05** B1 요약·B11 통계는 실시간일 필요가 없다. 매시간 집계 테이블(또는 Materialized View)을 갱신한다.

7.7 공고 자동 생성 (PRD 10장, 화면정의서 B4, CLAUDE.md 추가 요구사항)



- **TR-GEN-01 입력 스키마**: `jobCategory` (목록 선택), `careerLevel` (`NEW` / `Y1_3` / `Y3_5` / `Y5_PLUS`), `employmentType` (목록 선택), `codingTestRequired` (boolean), `companySituation` (≤100자), `skillKeywords` (최대 10개, 각 ≤20자). 긴 자유 서술을 서버에서도 거부한다(PRD 10.2).
- **TR-GEN-02 출력 스키마**: `{title, description, responsibilities[], requirements[], preferred[], conditions}`. Ollama `format` 으로 JSON 스키마를 강제하고, 파싱 실패 시 1회 재시도한다.
- **TR-GEN-03** `codingTestRequired` 값은 초안의 `coding_test_enabled` 기본값으로 그대로 들어간다(PRD 10.2). LLM 출력이 이 값을 바꿀 수 없다(서버가 덮어씀).
- **TR-GEN-04 프롬프트 인젝션 대응**: 단답형 입력은 프롬프트 안에서 "데이터" 구획에 따옴표로 감싸서 넣고, 시스템 지시와 분리한다.
- **TR-GEN-05** 편집 후에는 `review_confirmed` 를 **false로 되돌린다** [제안]. (화면정의서 B4가 운영 결정으로 남긴 부분. 검토 후 내용이 바뀌었으면 다시 검토하는 것이 안전하다)
- **TR-GEN-06** 미검토 게시(`forcePublish=true`)는 `published_without_review=true` 로 기록하고 PRD 8장 지표(생성 후 수정 비율)에 사용한다.
- **TR-GEN-07** 예상 소요 25~40초 [추정]이므로 반드시 스트리밍으로 보여준다. 90초 안에 끝나지 않으면 "생성이 지연되고 있습니다. 다시 시도해주세요"를 띄우고 입력값은 유지한다.
- **TR-GEN-08 차별 표현 주의 표시 [확정, D7]**
- 규칙 사전(`sensitive_terms_v{n}.yaml`)으로 초안을 검사한다. 항목: `pattern` (정규식), `category` (연령/성별/혼인/출신 지역/신체 조건/종교 등), `reason`, `suggestion`. LLM을 쓰지 않으므로 GPU 부담이 없다.
- 생성 API와 재검사 API(`POST /admin/job-drafts/check-terms`)가 `sensitiveTerms: [{field, start, end, category, reason, suggestion}]` 를 돌려주고, 화면정의서 v1.3 B4가 해당 위치에 밑줄 + 툴팁을 그린다.
- **게시를 막지 않는다.** 경고 건수와 게시 시점의 남은 건수를 `job_generation_logs.sensitive_term_hits` 에 기록한다.

- 한계: 사전에 없는 표현은 놓치고(예: "패기 넘치는 사회초년생"), 정상 표현에도 걸릴 수 있다(예: "여성의류 브랜드 MD"). 그래서 차단이 아니라 경고로만 쓴다. 사전은 버전 관리하고 오탐·누락 사례를 모아 갱신한다.

7.8 비동기 일정·알림 (PRD 6.7, Mermaid 07)

- **TR-NOTI-01** Celery Beat가 15분마다 알림 조건(지원 마감 임박 + 미완료 지원자, 공고 마감 하루 전, 일정 생성/변경)을 점검한다.
- **TR-NOTI-02** `notifications.dedup_key`를 `"{type}:{targetId}:{scheduledFor 날짜}"`로 만들고 unique 제약으로 중복 발송을 막는다.
- **TR-NOTI-03** 발송 실패 시 3회 재시도(1분 → 5분 → 30분). 그래도 실패하면 `FAILED`로 남기고 B10 발송 이력에 표시한다.
- **TR-NOTI-04** 일정 수락/조율 링크는 서명 토큰(itsdangerous)으로 만들고 DB에는 해시만 저장한다. 72시간 후 만료 [제안].
- **TR-NOTI-05** 개발 환경은 Mailpit SMTP로 받는다. 운영 SMTP 서비스 선정은 [미결정].
- **TR-NOTI-06 사이트 내 알림 [확정, D6]**: 면접 `REPORT_READY`, 코딩테스트 최종 체크 완료, 최종 결정 등록 시 `notifications(channel=IN_APP)` 행을 만든다. **메일은 보내지 않는다.** dedup_key(`"{type}:{applicationId}"`)로 같은 알림이 두 번 생기지 않게 한다. 클라이언트는 60초 폴링 + 화면 이동 시 조회한다(WebSocket/SSE 미사용 — 몇십 초 늦게 보여도 문제없는 알림이므로 단순한 폴링으로 충분하다).

7.9 평가 결과 공개 범위 (PRD 6.5 / 7.2 v1.2 변경, 화면정의서 A11/B6)

8.3의 "스키마 분리" 요구사항을 기능 관점에서 정리한 표 | 데이터 | 지원자 (A11) | 관리자 (B6) | |---|---|---| | 면접 항목별 점수, 총점 | ✅ (`REPORT_READY` 이후) | ✅ | | 면접 강점 3 / 개선점 3 | ✅ | ✅ | | 부분 평가 여부 (`isPartial`) | ✅ (안내 문구) | ✅ | | 면접 근거 인용 원문, 신뢰도, 검토 필요 | ❌ | ✅ | | 코딩테스트 중간 체크(정상/비정상 작동 + 출력·오류) | ✅ (응시 중, 본인 실행 결과) | ✅ (실행 이력) | | 코딩테스트 최종 체크(정답 맞힘/못 맞힘) | ✅ (`GRADED` 이후) | ✅ | | 코딩테스트 통과 개수, 세부 5항목 점수·근거 | ❌ | ✅ | | LLM 채팅 로그, 반려 이력, 감점 후보 | ❌ | ✅ | | 화면 이탈 이벤트 타임라인 | ❌ | ✅ | | 최종 합격/불합격/보류 | ✅ (결정 후) | ✅ |

---

8. 비기능 요구사항

8.1 성능 [추정 — 부하 테스트 후 확정]

ID	지표	목표 (개발 환경, 동시 면접 2명 기준)
TR-PERF-01	일반 API p95	≤ 300ms (PRD 7.1)
TR-PERF-02	답변 제출 → 다음 질문 표시 (꼬리질문 없음)	≤ 5초
TR-PERF-03	답변 제출 → 꼬리질문 표시	≤ 15초 (넘으면 생략, TR-AI-13)
TR-PERF-04	코딩 도우미 첫 토큰	≤ 5초 (대기열이 비었을 때)
TR-PERF-05	코드 실행 결과 (공개 테스트)	≤ 10초
TR-PERF-06	면접 종료 → `REPORT_READY`	대기열이 비면 ≤ 3분, 바쁠 때 ≤ 10분 (4.5 개선 반영)

ID	지표	목표 (개발 환경, 동시 면접 2명 기준)
TR-PERF-07	공고 초안 생성 완료	≤ 60초

8.2 보안

- **TR-SEC-01** 전 구간 HTTPS(개발: 로컬 인증서. `getUserMedia`는 localhost 외에는 HTTPS에서만 동작).
- **TR-SEC-02** 세션 쿠키 `HttpOnly; Secure; SameSite=Lax`, 유휴 2시간·절대 12시간 만료 [제안]. 로그아웃/비밀번호 변경 시 서버 세션 폐기.
- **TR-SEC-03** 서버 측 RBAC + 조직 범위 검사를 모든 API에 적용(TR-ADM-01). 화면 숨김만으로 대체하지 않는다.
- **TR-SEC-04** 음성·전사·채팅·코드 객체는 MinIO 서버 측 암호화(SSE)를 켜고, 서명 URL은 5분 만료.
- **TR-SEC-05** 관리자가 지원자 원본(음성·이력서·채팅)을 열람하면 `audit_logs`에 남긴다.
- **TR-SEC-06** 비밀값(DB 비밀번호, 세션 키)은 `.env`(커밋 금지) → 운영은 비밀 관리 도구 사용. `.env.example`만 커밋.
- **TR-SEC-07** 코드 실행기 격리(TR-CT-40), 정답 테이블 접근 차단(TR-CT-31).
- **TR-SEC-08** 업로드 파일은 확장자가 아닌 매직 바이트로 검사하고, PDF를 서버에서 렌더링하지 않는다(추출만).

8.3 공개 범위 강제 — 응답 스키마 분리 [확정, PRD 7.2]

- **TR-SEC-10** 지원자용 `ApplicantEvaluationSummary`와 관리자용 `AdminEvaluationDetail`을 **별도 Pydantic 모델**로 정의한다. 지원자 모델에는 관리자 전용 필드가 **아예 없다**(필드를 두고 null로 비우는 방식 금지 — 실수로 채워질 수 있음). `python class ApplicantEvaluationSummary(BaseModel): interviewStatus: str interviewScores: dict[str, float] | None interviewTotal: float | None strengths: list[str] | None improvements: list[str] | None isPartial: bool codingResult: Literal["CORRECT", "INCORRECT", "PENDING"] | None finalDecision: Literal["PASS", "FAIL", "HOLD", "UNDER_REVIEW"]`
- **TR-SEC-11** 계약 테스트: 지원자 API 응답 JSON에 `evidence`, `confidence`, `needsReview`, `codingScores`, `passedCount`, `totalCount`, `rejections` 같은 키가 **절대 나타나지 않음**을 테스트로 보증한다(11장).

8.4 안정성

- **TR-REL-01** 면접·코딩 세션 재개(TR-IV-40~42, TR-CT-10~12).
- **TR-REL-02** 멱등성: `Idempotency-Key` + 업무 키 unique 제약 이중 적용.
- **TR-REL-03** 모든 Celery 작업은 `background_jobs`에 `status/attempts/error_code`를 남기고(아키텍처 §11), 재실행해도 결과가 중복되지 않게 작성한다.
- **TR-REL-04** Ollama가 응답하지 않으면 게이트웨이가 헬스체크 실패를 감지해 P0는 즉시 생략(면접 계속), P1은 "AI 도우미 일시 중단, 코딩은 계속 가능" 안내 + 토큰 복원.
- **TR-REL-05** PostgreSQL 매일 `pg_dump` 백업 + MinIO 버킷 복제(운영). 개발은 Docker 볼륨.

8.5 확장성

- **TR-SCALE-01** LLM 서빙 교체 지점을 게이트웨이 하나로 제한한다. GPU 증설 시 Ollama → vLLM(OpenAI 호환 API)로 바꾸고 `OLLAMA_NUM_PARALLEL`/동시성 설정만 올린다(PRD 7.5).
- **TR-SCALE-02** STT 워커·실행기 워커는 수평 확장 가능하게(상태 없음) 만든다.
- **TR-SCALE-03** 동시 면접 상한(TR-AI-23)은 설정값이며, 하드웨어 확장 후 부하 테스트 결과로 올린다.

8.6 관측

- **TR-OBS-01** structlog JSON 로그, 모든 요청에 `requestId`를 붙여 api → 게이트웨이 → 워커까지 추적한다.
- **TR-OBS-02** 수집 지표(아키텍처 §13): API p95, LLM 대기/생성 시간, 큐 길이(우선순위별), GPU VRAM/사용률(`nvidia-smi`), STT 지연, 코드 실행 대기/실패율, 면접 중단율·재개 성공률, 꼬리질문 생략률(TIMEOUT), TTS 대체 발생률.

8.7 개인정보·공정성

- PRD 7.4를 그대로 따른다. 기술적으로는: 목적별 동의 기록(TR-RES-04), 원본 열람 감사(TR-SEC-05), 영상 미저장(TR-IV-12), 포커스 감지를 부정행위 확정에 쓰지 않음(TR-IV-53), 자동 채용 결정 API 없음.
- **D1 덕분에 생기는 이점**: 모든 AI 처리가 사내에서 이뤄지므로 동의서에 "외부 AI 서비스로 제공" 조항이 필요 없다.
- 보존 기간·삭제 주기는 미결정. 기간이 정해지면 Beat 작업으로 MinIO 객체와 DB 행을 함께 파기한다.

---

9. 브랜드 자산 기술 요구사항 (Huge / AIIT)

9.1 자산 현황

원본 (2026-10-26 확인) | 파일 | 내용 | 해상도/용량 | 웹 사용 문제 | |---|---|---|---| | `AI 채용을 돕는 휴지곽 로봇 Huge.png` | Huge 마스코트 포스터 (워드마크 + 슬로건 + 6단계 아이콘) | 1536×1024, **1.69MB** | 배경이 포함된 포스터라 그대로는 로고로 못 씀. 무거움 | | `글씨만 있는 로고.png` | AIIT 컬러 워드마크 + "AI Interview Training" | 1774×887, **423KB** | 투명 배경이지만 여백이 크고 무거움 | | `메인로고.png` | AIIT 흑백 조합 마크 (로봇+유모차 아이콘 + 워드마크) | 1254×1254, **855KB** | 흰 배경(불투명), 무거움, 다크 모드용 반전본 없음 |

웹용 가공본 (D8, 2026-10-26 생성 — `brand/`) | 경로 | 내용 | 용량 (WebP / PNG) | |---|---|---| | `logo/huge-wordmark(@2x)` | Huge 워드마크, 투명 배경 (포스터에서 추출한 **임시본**) | 7KB / 3KB (@2x 16KB / 8KB) | | `logo/huge-wordmark-white(@2x)` | 어두운 배경용 흰 글자 (반짝이는 파랑 유지) | 4KB / 2KB | | `logo/aiit-wordmark(@2x)` | AIIT 컬러 워드마크, 여백 제거 | 6KB / 4KB | | `logo/aiit-mark-black`, `aiit-mark-white` | AIIT 조합 마크, 투명 배경 검정 / 흰색 반전 | 56KB / 8~28KB | | `mascot/01-guide` ~ `06-better-hiring` | 6단계 마스코트 일러스트 (배경 포함 사각) | 4~6KB / 9~13KB | | `favicon/favicon.ico`, `icon-32/180/192/512.png` | 마스코트 얼굴 화면 + 흰 둥근 사각형 | 2KB ~ 120KB | | `og/og-image.jpg` | 포스터 상단 1200×630 | 84KB |

- 원본 대비 로고는 약 **98% 용량 감소**(423KB → 6KB 등).
- 생성 스크립트 처리 내용: 여백 자르기(trim), 밝은 배경 → 투명 변환, 흰색 반전본 생성, 256색 팔레트 PNG 최적화 + WebP 변환.

9.2 사용처 [확정: 화면정의서 공통 규칙 + 브랜딩 결정]

위치	자산	비고
지원자 GNB 좌측 (클릭 → A1)	**Huge 워드마크**	화면정의서 공통 규칙
관리자 사이드바 상단 (클릭 → B1)	**Huge 워드마크**	화면정의서 공통 규칙

위치	자산	비고
전체 화면 푸터	AIIT 컬러 워드마크(작게) + "Made by AIIT"	팀 크레딧
메일 템플릿 머리말, 평가 리포트 PDF	Huge 워드마크 + AIIT 흑백 마크	흑백 인쇄·메일 클라이언트 호환
파비콘 / 앱 아이콘	Huge 마스코트 얼굴(화면 부분) 크롭	작은 크기에서도 알아볼 수 있는 단순한 형태
링크 미리보기(OG 이미지)	마스코트 포스터 상단부 1200×630 크롭	
대기·완료·빈 화면 (A1, A8, A10, A11, B4)	`mascot/01~06`	D8 확정. 배치는 화면정의서 v1.3 C2

9.3 기술 요구사항

- **TR-BR-01 Huge 워드마크 [확정]**: 단독 원본 파일이 없어 포스터에서 추출한 **임시본**(`brand/logo/huge-wordmark*`)을 쓴다. GNB 높이(28~32px)에서는 충분하지만, 64px 이상 크기나 인쇄에서는 가장자리가 거칠 수 있으므로 **정식 SVG 워드마크 제작이 필요하다**(디자인 작업, 12장 U11).
- **TR-BR-02 포맷**: 웹은 WebP 우선 + PNG 대체(`<picture>` 또는 `next/image`). 용량 목표 로고 ≤ 30KB, OG 이미지 ≤ 200KB → 가공본 모두 충족(단, `icon-512.png` 120KB는 PWA 설치용이라 예외).
- **TR-BR-03 배경/여백**: 모든 로고는 투명 배경 + 여백 제거본으로 만들었다(가공 완료).
- **TR-BR-04 다크 모드**: 어두운 배경에서는 `huge-wordmark-white`, `aiit-mark-white`를 쓴다(가공 완료). AIIT 컬러 워드마크는 어두운 배경에 쓰지 않는다.
- **TR-BR-05 배치 경로**: 문서 저장소의 `brand/`가 원천이다. 웹 프로젝트를 만들면 `web/public/brand/`로 복사하고 Next.js `next/image`로 불러온다. 메일용은 MinIO 공개 버킷 `brand/`의 절대 URL + PNG를 쓴다(메일 클라이언트는 상대경로·SVG·WebP 지원이 약함).
- **TR-BR-08 마스코트 일러스트**: 배경이 포함된 사각 이미지이므로 연한 회청색 카드(`#F3F6FC`) 위에 둔다. 장식 이미지이므로 `alt=""`. 부정적 상황(강제 종료, 오류, 동시 응시 상한)에는 쓰지 않는다(화면정의서 v1.3 C2).
- **TR-BR-06 접근성**: 로고 이미지에 `alt="Huge 홈으로"`(GNB), `alt="AIIT"`(푸터)를 지정한다. 로고 링크는 키보드 포커스가 가능해야 한다.
- **TR-BR-07 색상 토큰 [추정: 이미지에서 추출한 근사값, 디자인 확정 필요]**: `css --brand-navy: #0F1B3D; /* 워드마크 진한 글자 */ --brand-blue: #2563EB; /* 주 강조색 (Primary CTA) */ --brand-blue-2: #3B82F6; /* 그라데이션 중간 */ --brand-sky: #7DD3FC; /* 그라데이션 밝은 끝, 반짝이 */ --text-sub: #4B5563; /* "AI Interview Training" 회색 */` 화면정의서의 "Primary CTA = 강조색 채움"은 `--brand-blue`로 연결한다. 텍스트 대비는 WCAG AA(4.5:1) 이상을 지킨다.

---

10. 기술적 제약사항

10.1 개발 환경

제약	내용	대응
OS	Windows 10 Pro	Celery는 Windows를 공식 지원하지 않고, gVisor는 Linux 전용 → **Docker Desktop(WSL2)** 안에서 실행

제약	내용	대응
Python	설치된 버전은 3.10.11, 요구는 3.12	3.12 설치 후 venv 재생성
GPU	VRAM 6GB, 1대	모델 1개 상주, 동시 추론 1건(4장)
CPU/RAM	STT·TTS·임베딩·Docker 서비스가 모두 CPU를 사용	**8코어 이상, RAM 32GB 권장** [추정]. 16GB면 Docker 메모리 한도를 조정해야 함
코드 실행 격리	Docker Desktop에서는 gVisor 사용 불가	개발: 일반 runc + TR-CT-40 제한 옵션 / 운영: Linux 호스트 + gVisor

10.2 개발용 docker-compose 서비스 구성 [제안]

```
services:
  postgres:       { image: pgvector/pgvector:pg17 }
  redis:          { image: "redis:7" }
  minio:          { image: minio/minio }
  mailpit:        { image: axllent/mailpit }
  api:            { build: ./backend }      # uvicorn app.main:app
  llm-gateway:    { build: ./backend }      # uvicorn app.gateway:app
  worker-general: { build: ./backend }      # celery -Q default
  worker-eval:    { build: ./backend }      # celery -Q eval
  worker-stt:     { build: ./backend-stt }  # celery -Q stt (CPU)
  worker-tts:     { build: ./backend-tts }  # celery -Q tts (CPU)
  beat:           { build: ./backend }      # celery beat
  runner:         { build: ./runner }       # 개발에서만 같은 호스트, 운영은 분리
# Ollama는 Windows 호스트에서 네이티브 실행 → host.docker.internal:11434
# Next.js는 호스트에서 npm run dev
```

10.3 비용·리소스

- 외부 AI API 비용: **0원**(D1). 대신 하드웨어(GPU·CPU·전력)가 비용이다.
- 실서비스 전환 시: 동시 응시자 수 목표 → 모델 크기·양자화·컨텍스트 → GPU 사양 순으로 **부하 테스트를 거쳐** 산정한다. 이 문서에서 임의의 운영 GPU 사양을 정하지 않는다(아키텍처 §13).

10.4 할 수 없거나 제한되는 것 (CLAUDE.md 제한사항 원칙 2: 솔직하게 명시)

항목	현황	대체 방법
6GB GPU에서 다수 동시 면접	**불가.** 1~2명 수준 [추정]	동시 면접 상한 + 거절 안내(D5), 실무 환경은 GPU 확장
실시간 꼬리질문의 일정한 응답 속도 보장	GPU가 밀리면 보장 불가	12초 타임아웃 후 생략(면접은 계속)
화면 이탈의 완벽한 탐지	브라우저 한계로 불가	억제 장치로만 사용, 관리자에게 타임라인 제공
LLM 함정 오류의 매번 동일한 재현	생성형 모델 특성상 어려움	고정 응답 시나리오 사용
스캔 PDF 자동 추출	MVP 제외	직접 작성 안내, 후속에 OCR

---

11. 검증 전략 (SDD / TDD)

11.1 원칙 [확정: CLAUDE.md]

- 각 `TR-*` 요구사항에 대응하는 테스트를 **먼저** 작성하고, 테스트가 통과하도록 구현한다.
- 실행: `python -m pytest` / 린트: `ruff check .` (프런트: `npm run lint`, `npx vitest`).
- 테스트 DB는 docker-compose의 별도 PostgreSQL(pgvector)을 쓰고, LLM·STT·TTS는 **가짜 구현(fake)**으로 바꿔 끼운다(게이트웨이 인터페이스 덕분에 가능).

11.2 반드시 먼저 작성할 테스트 (우선순위 순)

테스트	검증하는 요구사항
`test_returnTo_rejects_external_url` (`//evil.com`, `https://…`, `/admin` by 지원자)	TR-AUTH-02
`test_duplicate_application_returns_409`	TR-JOB-02
`test_applicant_evaluation_has_no_admin_fields`	TR-SEC-10, 11
`test_admin_cannot_read_other_org_application` → 404	TR-ADM-01
`test_penaltyForRejections_table` (0,1,2,3,4,5,9회 → 0,0,0.5,1.5,2.5,3,3)	TR-EV-12
`test_token_ledger_idempotent_on_retry`	TR-CT-21
`test_refund_restores_balance_without_deleting_rows`	TR-CT-23
`test_llm_usage_count_alone_never_penalizes`	TR-EV-13
`test_runHealth_wrong_output_is_normal`, `test_runHealth_exception_is_abnormal`, `test_runHealth_timeout_is_abnormal`	TR-EV-10 중간 체크 (D4)
`test_finalResult_all_match_is_correct`, `test_finalResult_one_mismatch_is_incorrect`, `test_finalResult_runtime_error_is_incorrect`	TR-EV-10 최종 체크 (D4)
`test_run_response_has_no_expected_output`	TR-CT-42
`test_capacity_full_returns_409_and_keeps_ready`, `test_concurrent_start_does_not_exceed_capacity`	TR-AI-23 (D5)
`test_report_ready_creates_in_app_notification_only` (메일 미발송)	TR-NOTI-06 (D6)
`test_finalize_answer_enqueues_pre_evaluation`	TR-EV-20 (D6)
`test_sensitive_terms_detected_but_publish_allowed`	TR-GEN-08 (D7)
`test_focus_loss_sets_terminated_not_interrupted`, `test_hidden_then_heartbeat_lost_is_terminated`	TR-IV-50~52 (D2)
`test_terminated_session_blocks_coding_test`	TR-CT-01
`test_partial_evaluation_counts_unanswered_as_zero`	TR-IV-61
`test_follow_up_limit_stops_at_4`	TR-IV-31
`test_partial_count_uses_base_questions`	TR-IV-60, 63 (꼬리질문은 문항 수에 넣지 않음)

테스트	검증하는 요구사항
`test_question_score_merges_follow_up`	TR-IV-63
`test_follow_up_timeout_skips_and_continues`	TR-AI-13
`test_gateway_db_role_cannot_select_test_cases`	TR-CT-31
`test_generated_draft_cannot_override_coding_flag`	TR-GEN-03
`test_edit_after_review_resets_review_confirmed`	TR-GEN-05
`test_rubric_weights_must_sum_100`	TR-ADM-03
`test_notification_dedup_key_prevents_double_send`	TR-NOTI-02

11.3 PoC로 측정할 항목 (구현 초기 1~2주)

1. 후보 LLM 2~3종의 한국어 면접 질문 품질 + 코드 답변 품질 + 6GB에서의 토큰/초.
2. faster-whisper small vs medium의 한국어 전사 정확도(CER)와 CPU 처리 속도.
3. TTS 후보의 한국어 자연스러움과 CPU 합성 속도.
4. 동시 면접 1/2/3명일 때 꼬리질문 지연 분포 → TR-AI-23 상한 결정.
5. STT 품질 불량 판정 기준값(`avg_logprob`, `no_speech_prob`).
6. 문항별 선평가(TR-EV-20)가 꼬리질문 지연·생략률에 주는 영향, 면접 종료 → `REPORT_READY` 실제 소요 시간.

---

12. 미결정 사항 및 후속 조치

#	항목	현재 기본값	결정 방법
U1	온프레미스 LLM 모델 종류 (PRD 9장)	한국어+코드 겸용 4~8B Q4 후보	PoC (11.3-1)
U2	STT 모델 크기	faster-whisper small int8	PoC (11.3-2)
U3	TTS 엔진	MeloTTS-KR / Piper-KR 후보	PoC (11.3-3)
U4	임베딩 모델과 벡터 차원	multilingual-e5-small 후보	PoC
U5	반려 차감량·감점 임계값 (PRD 9장)	정책 설정값으로만 존재	모의시험
U6	면접 재개 가능 기한	공고 마감까지	회의
U7	코딩테스트 중단 중 타이머 정지 여부	정지하지 않음 + 관리자 연장	회의
U8	데이터 보존·삭제 기간	—	회의 (개인정보 검토)
U9	운영 SMTP 서비스	개발은 Mailpit	운영 전
U10	동시 면접 상한	2	PoC (11.3-4)
U11	Huge 정식 SVG 워드마크	포스터 추출 임시본 사용	디자인 작업
U12	예상 대기 시간 화면 표시	서버 계산만, 표시 안 함	로그로 정확도 확인 후 결정

문서 후속 수정 — 완료(2026-10-26) - PRD v1.3: 진행 순서 고정(D3), 코딩테스트 2단계 공개(D4), 동시 응시 상한(D5), 사이트 내 알림(D6), 차별 표현 경고(D7), 강제 종료 0점(D9), 전부 온프레미스(D1) 반영. - 화면정의서 v1.3: A5/A6/A7/A8/A9/A10/A11/B4/B6 갱신, 공통 컴포넌트 C1(사이트 내 알림)·C2(마스코트) 추가.

13. 추가 기능 추천 처리 결과 (2026-10-26 사용자 결정)

#	추천 기능	결정	반영 위치
R1	면접 대기 안내	**축소 반영** — 대기열 대신 상한 초과 시 거절 안내. 예상 대기 시간은 계산만	D5, TR-AI-23
R2	평가 완료 알림 메일	**변경 반영** — 메일 대신 사이트 내 알림. 평가 지연 원인 분석 후 처리 시간 단축	D6, 4.5, TR-NOTI-06
R3	공고 차별 표현 필터	**반영** — 미리보기 밑줄 + 경고, 게시 차단 없음	D7, TR-GEN-08
R4	마스코트 일러스트	**반영** — 크롭·최적화 완료, 화면 배치	D8, 9장